

# 面向复杂任务的反馈感知多模型自适应有向无环图路由

Feedback-aware Adaptive DAG Routing for Multi-model LLM Collaboration

## 摘要

复杂任务包含信息抽取、关系推理和结果验证等不同能力需求，针对完整查询选择单一模型难以利用执行阶段间的模型互补。本文提出反馈感知的自适应有向无环图路由框架，将能力画像、节点级模型分配、静态执行与反馈条件化的后继适应相结合，并以选择性干预、预算约束和历史图复用组织多模型协同。财务复杂任务实验表明，冻结节点路由相对查询路由的条件化节点质量提高约 6.9 个百分点，主要收益来自阶段粒度；跨模型传播显示，上游输入来源能够改变下游优势，条件能力不能直接等同于传播能力。在枚举的 3×3 抽取—推理模型组合空间内，精确 Oracle 为 30.5%，最佳固定组合为 20.5%，但剩余差距未被当前选择器稳定利用。理想失败检测条件下的 48 任务真实调用比较中，动态第二版由静态的 52.1% 提高至 54.2%，差异不显著；在 250 个全新任务上的一次性冻结确认中该效应方向复现 (+2.8pp, 95% CI [-0.8,+6.4])，仍未达统计显著。而在含分支与汇合的四节点真实 DAG 面板上，选择性动态适应显著优于静态执行 (36.7% 对 16.7%, +20.0pp, 95% CI [11.7,28.3], Help/Harm 28/4)，且 933 次适配调用全部限于受影响后代闭包、分支隔离检查零违例、预算违规为零——动态 DAG 的价值在多节点结构下首次得到显著验证。对照消融显示增益主要来自失败节点升级至最强未试模型的动作（同目标静态对照 35.0%），而将失败检测全部换成部署可得信号（解析/执行与输出一致性检查，无 gold 参考）仍保留 91.7% 的增益 (35.0%)——动态收益不依赖理想失败检测。确认实验与开发层风险—覆盖率分析共同提示，限制无充分依据的切换有助于控制损害，但不能保证泛化收益；困难子集上较低的动作成功并集则揭示模型与动作覆盖的重要限制。研究支持在明确输入条件、反馈边界及资源口径的前提下，进行选择性的阶段级模型协同。

**关键词：**大模型路由；多模型协同；任务有向无环图；反馈适应；选择性路由；预算约束

## 1 引言

### 1.1 背景与问题

复杂任务通常需要完成信息抽取、关系推理、数值计算和结果验证。不同阶段对模型能力的要求并不相同：适合从长材料中定位事实的模型，未必最擅长根据事实形成运算关系；能够生成正确表达式的模型，也未必具有最可靠的验证能力。因此，多模型协同的目标不能仅表述为给完整问题寻找一个统一的最佳模型，还需要决定各执行阶段由谁完成，以及上游状态改变后是否应调整后续计划。

查询级路由通过预测模型效用在质量与资源之间作出选择，已有工作展示了偏好学习和成本控制的价值 [1,2]。然而，对具有依赖关系的任务，模型选择还受到输入来源的影响。一个模型在标准事实条件下的推理表现，不等于它消费实际抽取输出时的表现。同模型端到端执行将抽取与推理能力绑定，可能使上游弱项掩盖下游优势。只依据条件化节点成绩分配模型，或者只依据整条同模型链的成绩评价推理能力，都可能遗漏这一差别。

显式有向无环图 (Directed Acyclic Graph, DAG) 将中间结果与依赖关系变为可调度对象，使阶段能力能够独立组合。但分解会增加接口和资源开销，模型切换也可能破坏原本正确的输出。因此，需要同时

回答“是否存在互补机会”和“能否可靠选择这些机会”，并在执行反馈与剩余预算的约束下决定是否干预。

## 1.2 本文思路

本文提出反馈感知自适应 DAG 路由框架（Feedback-aware Adaptive DAG Routing），以模型能力画像支持控制路由，将复杂任务分解为初始 DAG，提供静态与动态两种执行模式。静态模式允许预定义局部回退，但保留后继模型计划；动态模式定义为反馈条件化的后续调整（Feedback-conditioned Downstream Adaptation），依据当前执行状态更新受影响后继的模型与恢复安排，不要求修改图拓扑。

框架采用选择性调整：保留已有强默认分配，只有在运行证据支持且资源允许时覆盖。预算控制决定恢复、升级或终止；图森林保存历史依赖与版本，在相关追问中复用仍然有效的节点。这些环节服务于共同的质量—成本—时延目标，而不是独立增加更多执行步骤。

研究围绕一条递进的证据链展开：首先测量阶段互补；随后考察实际输入传播如何改变可用能力；再通过跨模型组合和有限空间的精确事后上界定位剩余机会；最后检验选择性路由、动态恢复和预算约束能否利用这些机会。模型成功预测具有信号，并不意味着实例级最佳模型能够稳定预测；存在正 Oracle 差距，也不意味着该差距可以由当前表示与监督充分恢复。

## 1.3 贡献

第一，建立能力画像与 DAG 节点级异构模型分配的统一接口，并区分条件能力与传播能力。在冻结节点确认面板中，节点路由相对查询路由提高约 6.9 个百分点；类型先验取得相同平均质量，表明主要增益来自路由粒度。跨模型传播实验进一步展示，将抽取者与推理者独立分配可以利用同模型链中被掩盖的阶段优势。

第二，构建静态／动态双模式执行及选择性反馈调整。动态第二版在已分析的 48 任务真实调用面板上呈现正向但不显著的质量变化，并减少观察到的有害调整。该结果支持对反馈调度稳定性的有限判断，不构成普遍安全性保证；实验采用理想失败检测，其部署边界在方法与实验中明确披露。

第三，通过有限 3×3 组合空间的精确 Oracle、剩余差距路由、风险—覆盖率、恢复矩阵与证据诊断，系统分析可利用机会和能力边界。较小确认集中的正向选择信号未在更大确认集复现；固定恢复集合仅覆盖少量真实失败。结果说明，进一步优化调度既需要可靠选择信号，也需要模型与动作集合中实际存在正确候选。

## 1.4 论文组织

第 2 章比较模型路由、依赖执行、反馈与历史复用研究。第 3 章给出能力画像、节点分配、选择性动态执行与资源决策方法。第 4 章区分数据面板、信息条件和统计口径。第 5 章围绕八个研究问题组织结果，第 6 章解释条件能力、可路由性和能力覆盖之间的联系，第 7 章总结适用范围与后续方向。

## 2 相关工作

### 2.1 大模型路由与模型能力画像

RouteLLM 利用偏好数据学习查询到候选模型的选择，并评价质量与成本权衡。[1] 本文与其共享通过预测能力分配模型的目标，但选择对象为同一任务内部的类型化节点，且进一步研究执行后状态变化。节点基准的正差距并不意味着该差距一定可由问题编码预测，因此本文保留类型先验和事后最优选择作为不同参照。

FrugalGPT 研究通过模型调用策略降低开销并维持质量。[2] 本文同样关注有限资源下的选择，但将资源状态放在具有依赖关系的执行链中：一个恢复动作既消耗剩余预算，也改变后继输入。该区别是研究对象的细化，不构成对既有路由方法全面失效的判断。

### 2.2 任务分解与依赖图执行

LLMCompiler 将规划、任务分发与执行分开，利用依赖结构组织函数调用，并包含动态重新规划机制。[3] 本文借鉴显式依赖使执行过程可检查的组织思想，关注不同 LLM 在节点上的分工，以及失败后是否存在值得利用的替代能力。实验使用有限财务任务模板和小型链式图，不能据此宣称通用规划能力，也不将串行服务时长解释为并行图调度加速。

任务分解能够暴露中间接口，也增加接口错误和证据遗漏的机会。本文的严格配对三臂基准显示：同模型拆分本身在 TAT-QA 上显著有害 ( $-21.0\text{pp}$ )、在 MultiHieTT 上不显著 ( $+6.0\text{pp}$ )，而拆分后把推理阶段换为更合适模型带来总体  $+5.0\text{pp}$  显著增益——分解的价值是打开阶段分配接口，而非普遍提高推理，因此不应预设分解必然改善。

### 2.3 反馈驱动的自适应执行

Self-Refine 通过反馈与修订迭代改进生成结果。[4] 本文关注的反馈作用对象包括执行模型、局部恢复动作与后续计划，除了输出修订，还需要处理依赖失效和资源消耗。本文也将反馈信号的可靠性作为实验变量：标准答案可以支持离线判定，却不能等同于在线可得反馈。

因此，本文对反馈驱动执行的补充主要在于明确调度和评价边界。相同提示的重试、使用新提示的再次生成，以及根据金标准筛选正确候选，是不同操作，应分别记录和解释。

### 2.4 多目标执行与历史记忆

Agent Workflow Memory 从历史经验中形成可复用工作流程，为后续任务提供执行指导。[5] 本文的图森林重点保存具体任务的输入输出、依赖和版本，通过显式修改定位需要重算的部分。当前实现并不等同于通用语义 workflow 检索，也没有充分验证大规模图剪枝。

质量、调用成本与时延的权衡可通过约束优化和非支配关系表达。本文采用这些已有决策概念比较有限策略，主要考察约束如何改变恢复机会，以及复用如何减少资源需求，不将采用帕累托准则本身作为算法创新。

## 3 方法

### 3.1 框架概览

给定任务  $x$ 、材料  $D$  和模型池  $M$ ，控制器利用离线能力画像形成执行偏好，将任务分解为初始图  $G_0=(V_0,E_0)$ ，再为具体节点建立模型分配  $\pi_0$ 。执行过程中维护状态  $s_t$ 、反馈记忆  $H_t$  与剩余预算，选择保留计划、局部恢复或更新受影响后继。历史执行图以版本化集合  $F_t$  保存，支持相关请求复用。

整体流程为能力画像→控制路由→复杂任务分解→初始 DAG→静态／动态执行→选择性调整→预算控制→历史图复用。该顺序描述逻辑依赖：控制器在图构造前获得任务需求与资源偏好，具体节点分配在节点定义后完成，不另引入未实现的路由网络。

### 3.2 模型能力画像

模型画像包含质量  $Q$ 、token 消耗  $C$  与服务时长  $L$ 。必须区分两种输入条件。条件能力在标准前驱输入下评价当前节点；传播能力在实际前驱输出下评价节点或整条链。对于抽取模型  $e$  和推理模型  $r$ ，定义

$$Q_{e,r}(x)=E[Y|x,D,\text{Extract}_e(D,x),r].$$

同模型链  $Q_{\{m,m\}}$  同时受抽取与推理影响，不能作为模型  $m$  的纯推理能力。跨模型矩阵  $Q_{\{e,r\}}$  将两个角色分开，为分析阶段互补提供接口。

条件化节点路由使用冻结 GTE 问题编码、节点类型独热编码与问题长度：

$$\phi_i = \hat{c}$$

各模型的 Ridge 质量头在开发数据拟合，正则固定为 1。资源先验使用开发均值。后期 900 任务传播画像另以既有问题表示和可见输入统计评价质量与资源预测，并报告任务分组交叉验证；它不是对早期节点确认模型的测试后重训练。类型先验按照开发类型均值选择模型，用于区分类型粒度与额外实例表示的作用。

### 3.3 复杂任务分解与初始依赖图

节点  $v_i=(\tau_i, I_i, O_i, Pa(i), K_i)$  记录类型、输入输出约定、前驱和约束。边  $(v_j, v_i)$  表示后者依赖前者输出。主要类型包括抽取、推理、验证和汇总，转换节点在自然存在时保留。只有有效前驱输出齐备后，节点才具备执行条件。

现有实例使用可检查的领域模板。语义节点完成事实定位和关系选择，确定性执行器处理表达式运算。图构造不是已经训练的通用自由文本规划器。显式依赖使模型角色能够分离，也使局部接口错误可被定位，但不保证拆分优于整题生成。

### 3.4 能力感知节点路由

查询级选择为  $r_q: x \rightarrow m$ ，节点级选择为  $r_n: (x, \tau_i) \rightarrow m_i$ 。初始效用为

$$U(i, m) = \alpha \hat{Q}(i, m) - \beta \hat{C}(i, m) - \gamma \hat{L}(i, m), m_i^{\hat{c}} = \arg \max_{m \in M} U(i, m).$$

节点确认协议固定  $U = \hat{Q} - 0.05\bar{C}/1000 - 0.05\bar{L}/10$ 。系统保存候选预测与最终选择，不为展示多模型而强制平均分配。条件节点分数、同模型传播分数与跨模型组合分数对应不同输入条件，不互相替代。测试前封存表示、预测头和偏好；评价阶段不以标签重新调整模型分配。

### 3.5 静态依赖图执行

静态模式按初始依赖与分配执行。节点失败时允许冻结的局部回退；其结果作为后继实际输入继续传播，但后继模型计划保持不变。因此，静态不等于没有恢复，动态比较也不能仅通过增加调用预算获得优势。

执行记录包含请求、输出、解析状态、消耗及输入来源。缺失真实抽取输出时，不允许以标准事实隐式补齐部署快照。历史条件化实验中的标准事实仅按其原协议评价，并单独披露。中间节点存在缺陷与最终答案错误分别记录。

### 3.6 动态依赖图调整

动态模式统一定义为反馈条件化的后续调整。状态  $H_t$  记录已执行模型、实际结果、失败经历和资源消耗；更新对象可以是后继模型分配、恢复安排、预算可行域或验证策略。即使  $E_t$  不变， $\pi_t$  随新证据改变也构成动态执行。

受影响节点集合为  $A_t$ ，其依赖范围为  $A_t \cup \text{Desc}_G(A_t)$ 。未受影响且输入有效的节点保持原结果。局部分解可以改变结构，但不是动态定义的必要条件；既有局部重规划未扩大恢复覆盖，本文不将其作为成功组件。

反馈记忆与图调整具有不同作用。前者修正能力估计，后者改变后续执行选择。既有低容量实例使用类型、长度分桶、模型及失败状态计数；当前动作只应读取已经发生的反馈，未执行候选的事后质量不能用于实际选择。

检测信号必须区分运行异常与真实失败标签。解析错误、执行器异常及验证器拒绝是运行时可观测信号；最终答案是否正确通常只能离线判定。48 任务动态试验通过评价答案触发推理回退并更新失败计数，属于理想失败检测条件下的真实调用。本文以此评价给定可靠判定后的调度行为，不声称已完成无标准答案的在线闭环验证。

### 3.7 选择性调整

选择性策略优先保留强默认分配，在候选改善证据不足时不切换。动态第二版使用既有候选保护、受影响后继门控、关键节点处理、能力排序与预算可行性规则。其类型排序结合历史失败次数形成修正分数，替换须满足冻结差距条件。关键节点处理目前主要体现于两节点链的最终推理节点，不能扩展成已验证的大图关键路径算法。

剩余差距研究采用已经实现的两阶段选择器：第一阶段评价是否覆盖默认模型  $large$ ，第二阶段选择替代模型。简记为

$$r(x) = \begin{cases} \operatorname{argmax}_{m \neq m_0} s_m(x), & s_{switch}(x) > \tau, \\ m_0, & \text{otherwise.} \end{cases}$$

这是选择逻辑的表达，具体候选门槛保持冻结代码设置。确认实验的  $\tau=0.5$  在开发后固定。Ridge 决策分数未经概率校准，数值可以超出  $[0,1]$ ；不将高分误称为高置信度。两阶段传播路由与动态第二版是不同实例，前者的确认集结果不用于替代后者的动态执行结果。

风险—覆盖率分析考察覆盖默认策略的频率与 Help/Harm 的关系。其覆盖档位来自事后交叉验证分析，不转化为独立测试集上已经验证的固定安全阈值。

### 3.8 预算感知恢复

设预算为  $B_C$ 、 $B_L$ ，已发生消耗分别为  $c_j$ 、 $\ell_j$ ，则剩余预算为

$$B_C^{rem} = B_C - \sum_j c_j, B_L^{rem} = B_L - \sum_j \ell_j.$$

控制器在可行范围内选择恢复、升级或终止。既有动作集包括再次调用、切换模型、重新取证和局部分解。动作共享运行快照，标准答案、推导程序与 required operands 与运行输入隔离，仅供离线分类和评分。

预算响应面使用已记录动作的实际消耗筛选可行项，并按离线成功判定停止。因此它评价的是固定动作输出集合在不同剩余资源下的可达质量，不是实时预测开销的部署保证。动态实例的最小 token 门控也不等同于精确双预算控制。昂贵恢复只有在可行且存在新增覆盖时才有价值，动作复杂度本身不构成收益证据。

### 3.9 历史任务图复用

图森林  $F=\{G_1^{(v_1)}, \dots, G_k^{(v_k)}\}$  保存历史 DAG、子图、模型分配、反馈、可用质量与资源记录及版本。相关追问按检索、复用、修改、重算处理；输入含义和约束未变的节点可以保留，直接变化节点及受影响后继重新执行。

修改计算假设与修改源材料具有不同失效范围。前者可复用原材料抽取，后者需重做相关抽取。当前实现依赖显式任务标识和事实索引，已经验证小规模复用与版本化，未证明通用语义图检索和大规模剪枝效果。

### 3.10 多目标与约束决策

本文以约束质量最大化为主要表达：

$$\max_{p \in P} \hat{Q}(p) \text{ s.t. } \hat{C}(p) \leq B_C, \hat{L}(p) \leq B_L.$$

其中  $p$  包括模型分配和已有恢复策略。 $Q-C$ 、 $Q-L$  与  $Q-C-L$  非支配分析用于显示不同资源偏好下的候选权衡，不引入新多目标算法。资源相近时，质量差异是主要决策依据；预算收紧时， $C/L$  决定某一方案是否可行。

在两节点、三候选模型的固定组合分析中，定义  $A=M_E \times M_R$ ，包含九个组合。逐任务取其记录质量最大值后平均，得到“枚举  $3 \times 3$  模型组合空间内的精确 Oracle”。其最优性仅覆盖这九个既有输出；完整动态策略还包含反馈分支、恢复、停止和可能的结构变化，并未求得全局最优。预算约束 Oracle 使用实际开销，也只作为事后诊断上界。

## 4 实验设置

### 4.1 数据来源与评价面板

实验以 MultiHiertt 财务表文推理任务为主，并保留 TAT-QA 的既有分解对照作为补充。[6,7] 不同阶段使用不同面板，不能以相同数据集名称推定同一任务、输入条件或评分单位。官方无标签测试题不能沿用节点评分；节点确认采用经使用记录审计的有标签保留任务。表 4-1 汇总本文主要证据层级。

表 4-1 主要评价面板及用途

| 面板       | 规模                        | 输入与评价单位          | 证据层级               |
|----------|---------------------------|------------------|--------------------|
| 条件节点确认   | 100 任务、493 个主要节点          | 规定条件输入；节点质量      | 冻结选择器确认，评分更新另行审计   |
| 传播能力画像   | 900 任务                    | 同模型实际抽取至推理；任务正确率 | 开发数据、任务级五折交叉验证     |
| 跨模型传播    | 上述画像中 200 任务              | 实际抽取输出；九种组合      | 开发机制分析、有限组合 Oracle |
| Conf-200 | 200 任务                    | 同模型传播链           | 900 题训练后冻结确认       |
| Conf-500 | 500 任务                    | 同模型传播链           | 更大冻结确认             |
| 风险—覆盖率   | 上述<br>900+200+500=1,600 题 | 实际默认输出特征         | 合并后开发分析，不再独立       |
| 静态—动态    | 48 任务                     | 实际上游输出，理想失败判定    | 已分析面板、真实分歧调用       |
| 真实失败恢复   | 116 节点、96 任务              | 已审计失败快照          | 固定动作覆盖与预算回放        |
| 历史图复用    | 20 个追问                    | 显式修改与局部重算        | 特定多轮工作负载           |

四个转换节点不计入条件节点主表。跨模型的 200 题与 Conf-200 是不同面板，前者不能作为未见确认。旧 formal replay 使用预先记录的条件节点结果，不能替代真实传播；本稿以真实输入来源明确的矩阵与动态比较为主，不把历史 formal replay 均值并入主结果。

### 4.2 模型、表示与执行环境

核心候选池固定为 medium、large、coder，R1 不进入节点路由。别名对应既有协议的模型与服务配置；不同历史实验的生成配置遵循各自冻结版本，本轮未重新调用模型。条件节点预测器采用冻结 GTE 表示和 Ridge 头，类型先验不学习实例表示。后续传播画像与两阶段选择器按各自开发协议训练，与早期条件节点预测器区分。

实验在项目现有 GPU 与 vLLM 推理服务环境采集。资源比较以同面板记录为准；模型驻留、提示长度及接口会影响服务时长。本文不把服务时长总和称为包含加载、排队、调度的端到端墙钟延迟，也不从不同历史服务配置推断硬件加速。具体模型路径、采集脚本和协议由证据清单追溯。

### 4.3 对照与指标

对照包括查询路由、类型先验、冻结节点路由、强固定模型、固定跨模型组合、静态执行、动态执行以及不同候选空间的事后 Oracle。不同 Oracle 均标明候选集合；逐节点、三条同模型链、九种跨模型组合与恢复动作集合的上界不可互换。

节点质量是指定评分器的平均分；任务成功率是最终答案正确的任务比例。成本记录 tokens，调用次数单独计算；时延采用记录的服务时间。Help 指默认错误而新策略正确，Harm 指默认正确而新策略错误，二者之差对应正确任务数净变化。真实失败恢复率仅在原最终答案错误的集合上计算。历史复用率的分母为对应追问需要的逻辑节点数量。

对参考策略  $b$  与相同候选空间 Oracle，差距恢复比例定义为

$$GR(r; b) = \frac{Q_r - Q_b}{Q_{Oracle} - Q_b}.$$

分母须为正，且三项必须来自相同面板和评分口径。负值表示方法低于参考策略，不应截为零。该比例不是正确率，也不等于所有潜在协同机会已被覆盖。

#### 4.4 统计与信息边界

节点方法的配对区间按任务聚类，保留任务内节点关联；确认与动态比较按任务配对。本文沿用已有冻结结果和先前留档审计，不新增重采样实验。区间包含零时不称显著，少量 Help/Harm 不证明普遍安全。事后评分器复核与开发分析均明确标识。

标准答案、程序与必要操作数仅用于离线标签和评价，运行恢复输入应由真实快照构成。历史试验若使用标准事实、理想失败检测、事后已知开销或离线成功停止，则按相应条件解释。表中均值不构成线上开销保证；探索性诊断缺少完整配对来源时，不提升为正式确认结果。

### 5 实验结果与分析

本章围绕阶段互补、输入传播、组合上界、可路由性、选择性干预及恢复约束八个研究问题展开。条件化节点质量、传播链最终正确率和失败子集恢复率分别报告；不同面板的均值不直接合并。主要结果编号与来源在 FINAL\_CLAIM\_AUDIT.md 中对应。

#### 5.1 阶段级能力互补是否存在

在 100 任务、493 个主要节点的冻结确认面板上，三候选模型分别执行节点，以扩展执行器统一评分。推理与验证采用基准规定的条件输入，因此本节首先测量阶段能力，而不是完整链成功率。

表 5-1 不同节点类型的条件化质量

| 类型 | 节点数 | medium | large  | coder  | 逐节点 Oracle |
|----|-----|--------|--------|--------|------------|
| 抽取 | 193 | 0.3731 | 0.5959 | 0.3782 | 0.6943     |
| 推理 | 100 | 0.3100 | 0.2500 | 0.3100 | 0.4100     |
| 验证 | 200 | 0.5200 | 0.4550 | 0.5900 | 0.6200     |

large 在抽取上占优，medium 与 coder 的推理均值并列最高，coder 的验证质量最高。类型内 Oracle 相对最佳固定模型分别存在约 9.84、10.00 和 3.00 个百分点的差距。模型优势因阶段而异，为节点级选择提供经验依据；Oracle 使用事后标签，不能直接证明这些机会可被输入特征预测。

表 5-2 冻结路由与类型先验比较

| 方法             | 平均节点质量 | 每任务 tokens | 每任务服务时间总和（秒） |
|----------------|--------|------------|--------------|
| Always Large   | 0.4686 | 4,991.02   | 11.71        |
| 查询路由           | 0.4665 | 4,985.33   | 10.19        |
| 类型先验           | 0.5355 | 未独立汇总      | 未独立汇总        |
| 冻结节点路由         | 0.5355 | 4,856.43   | 7.79         |
| 新版矩阵逐节点 Oracle | 0.6065 | 不作部署比较     | 不作部署比较       |

节点路由相对查询路由提高 6.90 个百分点，并减少记录中的 token 与服务时间。以 Always Large 为参考，其条件化节点 GAP Recovery 为  $(0.5355-0.4686)/(0.6065-0.4686)$ ，约 48.5%，即接近一半。这里的“接近一半”是差距恢复比例，不是任务准确率。

类型先验与节点路由的均值相同，说明主要收益来自阶段粒度，而非问题表示的额外学习能力。上一版矩阵复核的任务聚类区间表明，节点路由相对查询路由差异为正，而相对类型先验区间包含零。原结果中 0.6045 是旧 Oracle 选择在新评分器下的重评分；本表采用已留档复核的新版逐节点最大值 0.6065，不混用两者计算差距。

## 5.2 条件互补为何不能直接转化为传播收益

900 任务画像使推理模型消费同模型实际抽取结果，测量传播链能力。任务级五折交叉验证保持同任务节点同折。

表 5-3 传播画像中的预测与路由结果

| 指标              | medium | large  | coder  |
|-----------------|--------|--------|--------|
| 单模型成功预测 ROC-AUC | 0.7511 | 0.7880 | 0.8391 |
| 传播路由策略          |        | 最终质量   |        |
| 最佳固定模型／类型先验     |        | 0.1800 |        |
| 查询路由            |        | 0.1778 |        |
| 能力画像路由          |        | 0.1789 |        |
| 同模型链 Oracle     |        | 0.2300 |        |

单模型成功存在可预测信号，但能力画像路由没有超过类型先验，差异区间  $[-0.0111, 0.0089]$  包含零。900 个任务中，693 个三模型链均错、50 个均对、157 个存在模型间结果差异。大量共同失败和共同成功会使整体最优模型命中率受并列情况抬高；判断可路由性应关注模型表现不同的任务及最终质量差异。

标准事实推理基准中的最佳固定质量为 0.31、逐任务推理 Oracle 为 0.41，存在 10 个百分点的条件空间。传播画像中最佳同模型链为 0.18、Oracle 为 0.23，只保留 5 个百分点的整链选择空间。但这两组数据的任务集和估计对象不同，不能把差值解释为严格配对的“抽取噪声损失”。零调用审计

（REASONER\_ROW\_ORACLE\_AUDIT.json，冻结评分器逐任务重算）给出各面板的传播 headroom：900 题开发集 5.00pp、Conf-200 4.50pp、Conf-500 5.40pp、合并 1,600 题 5.06pp；共同失败占比 77.0%／

76.5%/76.2%/76.7%。本文统一引用上述审计值；此前口径外的“传播后 4.1pp”说法查无冻结来源，作废。下一节通过固定推理者、更换上游来源提供更直接的机制证据。

由此，条件能力与传播能力必须分开估计；前者揭示理想输入下的能力，后者反映整个输入生成过程与下游执行的联合作用。

### 5.3 跨模型组合能否释放阶段互补

在能力画像的 200 任务子集上，实际执行三个抽取模型与三个推理模型的九种组合，推理者消费对应抽取者输出。该子集用于开发机制分析，不是 Conf-200 确认集。

表 5-4 跨模型传播矩阵

| 抽取模型／推理模型 | medium | large | coder |
|-----------|--------|-------|-------|
| medium    | 10.0%  | 9.5%  | 9.5%  |
| large     | 20.0%  | 18.0% | 20.5% |
| coder     | 13.0%  | 11.5% | 11.0% |

保持推理者 medium 不变，将抽取者从 medium 换成 large，质量由 10.0% 提高至 20.0%；保持推理者 coder 不变，对应变化为 11.0% 至 20.5%。固定 large 抽取后，medium 和 coder 的推理结果分别高于 large 推理的 18.0%。这表明同模型链可能因抽取弱项而掩盖下游优势，独立分配阶段模型能够解除这种绑定。

上述比较支持阶段互补的机制解释，但当前未据该汇总表宣称各点估计差异均达到统计显著。large 抽取均值更好也不意味着它在每个任务上都是最优来源。

DAG 的价值因此不应被简化为“拆分总提高性能”。为把分解效应与模型选择效应分开，本文冻结 300 个任务（MultiHiertt 100、TAT-QA 200；任务标识与历史协议污染经审计，抽取失败即判失败、不重试、不喂标准事实）并在一次统一推理会话中执行三臂分解基准：Mono-L（单体 large 直接作答）、DAG-L/L（large 抽取→large 推理→确定执行）与 DAG-L/M（同一抽取输出→medium 推理→确定执行）。两个 DAG 臂共享同一次抽取、全部提示与生成配置，因此表 5-5 只改变“是否拆分”，表 5-6 只改变“推理模型”。

表 5-5 严格配对分解基准：拆分本身（Mono-L vs DAG-L/L）

| 数据集         | 配对 N | Mono-L | DAG-L/L | ΔQ      | 95% CI        | Help／Harm | McNemar p            |
|-------------|------|--------|---------|---------|---------------|-----------|----------------------|
| MultiHiertt | 100  | 11.0%  | 17.0%   | +6.0pp  | [−2.0,+14.0]  | 11／5      | 0.21                 |
| TAT-QA      | 200  | 52.5%  | 31.5%   | −21.0pp | [−28.5,−13.5] | 14／56     | 4.3×10 <sup>−7</sup> |
| Overall     | 300  | 38.7%  | 26.7%   | −12.0pp | [−18.0,−6.0]  | 25／61     | 1.3×10 <sup>−4</sup> |

ΔQ 为任务级配对差值 DAG−Mono 的均值，95% 区间为 10 000 次配对 bootstrap，p 为精确 McNemar 检验。同模型拆分本身在 TAT-QA 上显著有害（−21.0 个百分点，Harm 56 远多于 Help 14），在 MultiHiertt 上为不显著的正向信号（+6.0 个百分点），总体 −12.0 个百分点且区间不含零。分解不自动带来收益：它引入真实的接口损耗，损耗集中于简单任务（见下表）。

表 5-6 严格配对分解基准：异构阶段分工（DAG-L/L vs DAG-L/M）

| 数据集         | 配对 N | DAG-L/L | DAG-L/M | $\Delta Q$ | 95% CI       | Help/<br>Harm | McNemar p |
|-------------|------|---------|---------|------------|--------------|---------------|-----------|
| MultiHiertt | 100  | 17.0%   | 15.0%   | -2.0pp     | [-7.0,+3.0]  | 2/4           | 0.69      |
| TAT-QA      | 200  | 31.5%   | 40.0%   | +8.5pp     | [+3.5,+13.5] | 22/5          | 0.0015    |
| Overall     | 300  | 26.7%   | 31.7%   | +5.0pp     | [+1.3,+8.7]  | 24/9          | 0.014     |

拆分之后把推理模型从 large 换成 medium：TAT-QA 显著追回 +8.5 个百分点，总体 +5.0 个百分点；MultiHiertt 上 medium 推理不优于 large（-2.0 个百分点，不显著），说明阶段互补是任务依赖而非普适。但即使加上异构分工，DAG-L/M 总体 31.7% 仍低于 Mono-L 的 38.7%：异构分配显著缓解了解析造成的性能损失，但在当前 300 题总体上尚未完全抵消该损失。据此，DAG 分解本身不应被宣称为质量提升手段；其作用是解除执行阶段之间的同模型绑定，为阶段级异构能力分配提供结构接口，最终受益取决于分解接口损耗与模型阶段互补性之间的平衡。

表 5-7 复杂度分层下的分解效应（表 5-5 对照）

| 数据集         | 复杂度   | N   | Mono-L | DAG-L/L | $\Delta Q$ |
|-------------|-------|-----|--------|---------|------------|
| TAT-QA      | 1-2 步 | 177 | 53.1%  | 26.0%   | -27.1pp    |
| TAT-QA      | 3 步   | 19  | 52.6%  | 73.7%   | +21.1pp    |
| TAT-QA      | 4 步以上 | 4   | 25.0%  | 75.0%   | +50.0pp    |
| MultiHiertt | 1-2 步 | 86  | 10.5%  | 16.3%   | +5.8pp     |
| MultiHiertt | 3 步   | 9   | 11.1%  | 33.3%   | +22.2pp    |
| MultiHiertt | 4 步以上 | 5   | 20.0%  | 0.0%    | -20.0pp    |

复杂度按答案推导的算术步数计（TAT-QA 推导式二元运算符、MultiHiertt 程序函数调用）。TAT-QA 上分解效应随复杂度单调上升（-27.1  $\rightarrow$  +21.1  $\rightarrow$  +50.0 个百分点），简单任务的损害高度集中（1-2 步层 Help 4/Harm 52，McNemar  $p \approx 1.1 \times 10^{-11}$ ）；MultiHiertt 未复现该趋势且各层区间均跨零。因此“何时值得拆分”的证据是复杂度依赖的：随推理复杂度增加，显式分解的相对价值呈上升趋势；3 步与 4 步以上子层样本很小（ $n=19$ 、 $n=4$ ），该分层仅作描述性机制证据，不构成“超过某步数必须拆分”的规则。成本口径：DAG 两臂平均 token 高于单体（总体 1737  $\rightarrow$  2189），异构分工相比同模型分解几乎不增加 token；服务时间为同一推理环境下的观测值（Mono 2.63s、DAG-L/L 3.13s、DAG-L/M 3.08s），不解释为稳定算法加速。旧配对数字（MultiHiertt +14.0pp、TAT-QA -9.38pp）来自协议不净的历史采集（部分推理节点使用标准事实或回退标准事实、模型逐题变化），自本文起撤回，仅在早期探索记录中保留。

## 5.4 距离有限组合空间的精确上界还有多远

本节依据最终索引审计，逐任务枚举九种已执行组合，取最终正确性的最大值并平均。所有 200 $\times$ 9 个记录均有对应单元。

表 5-8 枚举组合空间的上界与差距

| 对象                                 | 质量    | 与精确 Oracle 的距离 |
|------------------------------------|-------|----------------|
| Always Large:<br>E_large → R_large | 18.0% | 12.5 个百分点      |
| 最佳固定组合:<br>E_large → R_coder       | 20.5% | 10.0 个百分点      |
| 枚举 3×3 空间内精确 Oracle                | 30.5% | 0              |

最佳固定跨模型组合相对 Always Large 增加 2.5 个百分点，恢复对应 12.5 个百分点 Oracle 差距的 20.0%。剩余 10.0 个百分点表示在这九种记录中仍有任务特定机会，不表示当前路由器一定能够预测它们。

该上界的完整名称是“枚举 3×3 模型组合空间内的精确 Oracle”（Exact Oracle within the enumerated 3×3 model-composition space）。它不包含任意恢复序列、图结构、提示变体或动态预算分支。有限组合穷举不能被表述为完整 Dynamic DAG 的全局最优解。

## 5.5 剩余差距能否可靠学习

剩余差距路由以 large 为强默认，使用 900 任务开发数据拟合两阶段选择器，固定阈值  $\tau=0.5$  后分别评价较小 Conf-200 与较大 Conf-500。这里的 Oracle 仅取三条同模型传播链，与上一节九组合 Oracle 不同。

表 5-9 冻结两阶段路由的确认结果

| 指标             | Conf-200         | Conf-500          |
|----------------|------------------|-------------------|
| 任务数            | 200              | 500               |
| large 默认质量     | 0.1900           | 0.1840            |
| 两阶段路由质量        | 0.2000           | 0.1780            |
| 同模型链 Oracle    | 0.2350           | 0.2380            |
| 质量差异           | +1.00 个百分点       | -0.60 个百分点        |
| 质量差异 95% 区间    | [0.00,2.50] 个百分点 | [-1.60,0.20] 个百分点 |
| GAP Recovery   | +22.22%          | -11.11%           |
| 切换次数           | 4                | 22                |
| Help/Harm      | 2/0              | 1/4               |
| McNemar 精确检验 p | 0.500            | 0.375             |

较小确认集出现正向信号，但差异不显著；在更大确认集上未复现，点估计转负且同样不显著。因此不能将 +22.22% 作为稳定主结果，也不能反向断言剩余差距完全不可学习。

在 Conf-200 上，能力画像路由与成对路由分别切换 135 和 137 次，质量为 0.16 和 0.15，低于默认的 0.19；两阶段策略只切换 4 次。该比较提示无充分依据的覆盖会引入损害，但不同选择器也改变评分方式，不能把差别全部归因于切换次数。

Conf-500 的机制分析在 34 个仅 large 占优任务与 27 个替代者占优任务上，触发分数的诊断 AUC 为 0.458；medium 偏好分数仍有一定信号，但不保证触发和目标选择同时正确。这说明单模型成功可预测、相对优劣可排序以及最终路由有净收益，是不同层次的问题。

## 5.6 低覆盖率选择为何相对安全

为分析覆盖默认策略的代价，既有研究将 900 开发任务、200 和 500 个已分析确认任务合并为 1,600 题开发语料，进行任务级五折预测与事后风险—覆盖率分析。运行时特征来自 large 的实际抽取和推理输出；这一评价不能再称为独立确认，也不等同于零执行成本的到达时路由。

表 5-10 开发语料上的事后风险—覆盖率曲线

| 覆盖率 | 覆盖默认次数 | Help | Harm | 净改善数 | GAP Recovery |
|-----|--------|------|------|------|--------------|
| 2%  | 32     | 2    | 0    | +2   | +2.47%       |
| 5%  | 80     | 6    | 0    | +6   | +7.41%       |
| 10% | 160    | 8    | 1    | +7   | +8.64%       |
| 15% | 240    | 8    | 6    | +2   | +2.47%       |
| 30% | 480    | 12   | 15   | -3   | -3.70%       |
| 50% | 800    | 22   | 39   | -17  | -20.99%      |

在该分析中，5%—10% 覆盖具有正净收益且损害较少；扩大覆盖后，新增有害覆盖逐渐抵消帮助。它支持限制干预范围的机制动机，不证明 5%—10% 是新任务上的通用安全区间，更不能在看到曲线后将这些档位称为事先冻结阈值。

既有流程在拆分前进行全体无标签特征标准化，且覆盖档位为事后解释，因此本节保留开发层级。没有新调整评分器或覆盖阈值，也不以本节结果撤销 Conf-500 未复现的结论。

## 5.7 动态执行能否利用反馈调整后续策略

最新动态对照使用已分析的 48 任务真实调用面板。静态允许局部回退，动态使用反馈更新执行选择。第二版复用已记录的静态前缀并执行分歧请求；真实上游输出进入下游，但推理失败检测与失败计数读取评价答案，属于理想失败检测条件下的 live 实验。

表 5-11 静态与动态执行

| 策略    | 正确任务  | 正确率    | 平均 tokens | 服务时长（秒） | Help/Harm |
|-------|-------|--------|-----------|---------|-----------|
| 静态    | 25/48 | 52.08% | 1,402.2   | 2.95    | —         |
| 动态第一版 | 26/48 | 54.17% | 1,403.8   | 2.89    | 2/1       |
| 动态第二版 | 26/48 | 54.17% | 1,400.6   | 3.09    | 1/0       |

第二版相对静态约 +2.08 个百分点，已有逐任务复核区间 [0,6.25] 个百分点包含零，差异不显著。第一版相应区间为 [-4.17,10.42]。第二版减少观察到的 Harm，同时也少一个 Help，总正确数未变化；其服务时间略高于静态，不能写成 Q/C/L 全面占优。

实现中 25/48 个任务带重调度标记，包含局部回退，不能等同于多后继全局调整。token 预算违规为零，但预算基准取静态实际消耗的 1.2 倍，非到达时即可知道的预算。该面板此前已分析，不是未经接触的 held-out test。

开发层受控故障提供补充机制证据：模型分配干预中出现 Help=2、Harm=0；证据缺失为 1/1，错误中间值为 0/0。无干预对照仍有一例损害，且原恢复率汇总存在计数错误，故本稿只保留已复核

Help/Harm，不据此宣称严格的单因素因果证明。动态策略能够利用某些既有替代机会，但不能保证修正所有上游错误。

为把“+2 个百分点左右的小效应”与样本波动区分开，本文在 250 个全新的 TAT-QA train split 任务上做了一次性冻结确认（dynamic\_v2\_confirm\_250，策略与阈值同 48 任务面板逐字一致，选择规则与任务清单在任何调用前冻结并提交；与工作区全部历史工件零重叠）。结果：静态 103/250（41.2%）、动态 110/250（44.0%），配对  $\Delta Q = +2.8pp$ ，任务级 bootstrap 95% CI [-0.8, +6.4] 覆盖零；McNemar 精确检验  $b=13$ 、 $c=6$ ， $p=0.167$ ；Help/Harm = 13/6；平均 tokens 略低于静态（1,337.5 对 1,350.3），预算违规 0。按预注册三情形判定为情形二：**方向在第二个独立面板复现（+2.1 → +2.8），规模一致，但统计上仍未确证**。本文如实报告：动态第二版的端到端质量收益应描述为“在两个独立面板上方向一致的小幅正向信号”，不是已确证的改进；其可确证的价值仍是 harm 控制与零预算违规。

多节点结构验证。上述两面板均为两节点链；为回应“自适应 DAG 与两阶段流水线有何区别”，本文构建了真实的四节点 DAG 面板（multidag\_dynamic\_120，120 个全新任务，策略在任何调用前冻结并提交）：e1（表格抽取，large）与 e2（文本抽取，large）并联为分支，r（汇总表达式生成，medium）为汇合点，v（数值校验，coder）为尾节点；仅选择 gold 答案同时需要表格与文本区域的任务（TAT-QA answer\_from = table-text），保证分支在结构上不可退化。两臂共享初始分配、prompt、生成配置与预算规则（1.2×静态实际消耗），失败检测为理想条件，差异仅为冻结的适应规则（静态：每失败节点一次本地回退  $e \rightarrow coder$ 、 $r \rightarrow coder$ 、 $v \rightarrow medium$ ；动态：抽取失败记忆切换、r/v 升级 large 并受预算门控）。结果：静态 16.7%、动态 36.7%，配对  $\Delta Q = +20.0pp$ ，95% CI [11.7, 28.3] 不含零；McNemar 精确检验  $b=28$ 、 $c=4$ ， $p \approx 1.9 \times 10^{-5}$ ；Help/Harm = 28/4；动态成本略低（-90 tokens）、预算违规 0。选择性更新审计：933 次适配调用的每一次都属于某失败节点或其声明后代闭包（越界 0 次）；分支隔离检查 134 例全部通过——单侧分支失败时，干净分支从未被重执行，即**只更新真正受影响的后代，从不全图重跑**。这是本文第一次在含分支与汇合的多节点真实传播下得到 Dynamic 显著优于 Static 的证据。同时如实说明边界：区域受限抽取（仅表格或仅文本）的失败率（158/480 节点槽位）远高于全上下文抽取；校验尾节点几乎在所有任务上都触发适配，动态收益相当部分来自 r/v 升级 large；结论限于该任务结构、单域与理想失败检测条件。

公平性与真实反馈消融（multidag\_ablation\_120，两个预注册对照臂，同一冻结面板，830 次新调用）。**Static-Matched 臂**保持静态语义但将恢复目标换成动态的升级目标（r 失败  $\rightarrow$  large、v 失败  $\rightarrow$  large）：Q = 35.0%（+18.3pp，CI [10.0, 26.7]），完整动态策略 36.7%——策略超出目标选择的额外贡献仅 +1.7pp（CI [-4.2, +7.5]，McNemar  $p=0.77$ ）。**归因如实报告：主要质量增益来自“失败节点升级至最强未试模型”这一动作本身；动态框架的可确证价值在于以选择性更新与预算约束安全地承载该动作**。**Dynamic-RealDetector 臂**将失败检测全部替换为部署可得信号（解析/执行检查加 v 与 r 的输出一致性，无 gold）：Q = 35.0%，**增益保留率 91.7%**（CI [77.8%, 100%]），与理想检测无显著差异（ $p=0.5$ ），成本更低（2,459.5 tokens）。机制边界如实说明：尾节点一致性检查在本面板近乎全触发（离线审计已表明其退化为常发），等价于“尾节点总是请求更强模型复核”；r 节点的值错误检测不到，但该缺口在本面板代价很小。结论：**动态 DAG 的收益不依赖 gold 失败信号**。

## 5.8 恢复、预算与能力覆盖如何限制收益

### 5.8.1 真实失败与动作覆盖

原 148 个缺陷节点中有 32 个原最终答案已正确，审计后恢复集合为 116 个节点、96 个任务。恢复以原最终答案错误为前提，避免将再次答对原本正确的任务计为救回。

表 5-12 固定恢复动作的真实失败覆盖

| 失败类型 | 节点数 | 再次调用 | 切换模型 | 重新取证 | 局部分解 |
|------|-----|------|------|------|------|
| 证据类  | 45  | 0    | 1    | 2    | 1    |
| 推理类  | 48  | 0    | 1    | 1    | 1    |
| 结构类  | 23  | 2    | 0    | 2    | 0    |
| 合计   | 116 | 2    | 2    | 5    | 2    |

各动作成功集合重叠，其并集仅为 8/116，即 6.90%。当前主要限制包括动作集合本身覆盖不足；即使选择完全正确，也无法恢复该固定集合没有成功输出的节点。这一结论仅限该困难集合及固定模型、提示与动作，不是所有任务的唯一瓶颈。两个再次调用的真实恢复案例并未保持原提示，因此不证明零温度同提示重试有效。

局部子图重规划在独立开发的 40 节点上仅成功 1 个，加入后动作并集仍为 4/40，新增覆盖为零，按既有规则判定 NO-GO。拓扑变化没有自动扩展覆盖，不作为本文正贡献。

### 5.8.2 剩余预算与多目标权衡

预算响应面使用 116 节点的已测动作开销，在 11×7 个 token／服务时间档位上回放。

表 5-13 四动作顺序策略的剩余预算响应

| token 预算 | 时间预算（秒） | 恢复率   | 同预算动作 Oracle |
|----------|---------|-------|--------------|
| 500      | 1       | 2.59% | 3.45%        |
| 1,000    | 2       | 3.45% | 4.31%        |
| 2,000    | 3       | 4.31% | 5.17%        |
| 3,000    | 3       | 5.17% | 5.17%        |
| 无上限      | 无上限     | 6.90% | 6.90%        |

紧预算限制昂贵动作，预算放宽增加可行覆盖，但最终仍止于固定动作并集。回故事先知道实际消耗，并用离线成功停止；零违反是可行性筛选的结果，不证明部署时具有准确时延预测。

在九组合面板中，固定 large 抽取的三种推理组合成本约 4,430—4,436 tokens，服务时间约 5.08—5.19 秒，质量分别为 20.0%、18.0%、20.5%。正常预算下它们的资源差异较小，质量是主要区分轴；三点在记录均值上存在非支配权衡，不能据极小资源差异断言稳定优势。预算收紧后，资源项转为可行性条件。该观察限于当前组合与环境，不扩展为所有模型池的共同性质。

### 5.8.3 证据改善为何不必然带来正确答案

已有结构感知解析诊断关注原同模型链共同失败的开发子集。零调用审计

（EVIDENCE\_DIAGNOSIS\_AUDIT.json，含 commit 与全部输入哈希）给出其可复核边界：25 个结构推

理应答全部可解析，按冻结评分器重打分  $Q = 0/25$ ，与保存的评分汇总一致；但“25 条记录均覆盖必要操作数”这一早期工件不可复现——以当前版本化代码重算，top-30 候选对 gold 操作数的覆盖为  $0/25$  任务、全量解析事实为  $14/25$ （原生成代码未版本化，早期覆盖数字不具审计效力，不予引用）。可审计的结论因此收窄为：结构化解析未产生任何正确答案，且其“覆盖恢复”前提本身无法复核。

对 D2—D4 变体：保存应答各  $25/25$  可解析，但配对输入未冻结，成功率不可重算，本文不报告任何来自会话记录的百分比；D0、D1 与 Dev-25 上的 gold-facts 臂没有已定位的冻结输出，相应口头数字（0%、4%）同样无审计工件支持。节点基准条件口径的 medium 推理  $Q = 31\%$  属另一测量，不移植为该子集的成功率。作为补充，对 100 个 large 抽取→medium 推理失败任务上已冻结但此前未评分的证据重建调用进行首次评分：S0 基线/S1 重抽取/S2 跨模型/S3 定向缺失证据重建的  $Q = 8\%/8\%/5\%/8\%$ ，基线抽取操作数覆盖均值仅 35.4%——即使让模型主动检索缺失量并合并证据，成功率也不高于基线（探索性分析，非预注册）。

结合固定动作覆盖与跨模型传播结果，可以保守判断：证据检索、选择与模型路由的进一步改善未在所分析困难样本上形成稳定恢复证据；当前模型及动作覆盖是主要剩余瓶颈之一。不能据此否定更强证据推理、工具或模型在未来扩大可解集合的可能。

#### 5.8.4 历史图复用的独立作用

图森林在 20 个修改型追问中复用 40 个抽取节点，新执行 40 次调用，相对 80 次逻辑重执行需求减少 50%，记录 token 减少 91.4%。19/20 个流程可以执行且结果响应修改，但验证器接受为  $0/20$ ，因此该结果证明特定多轮工作负载的复用与资源机制，不证明 95% 答案正确率。多轮复用不并入单轮动态正确率，图剪枝也不列为已验证贡献。

### 5.9 跨域探索：数学推理域（探索性负结果，已被正式协议接续）

为检验核心机制是否只在财务表格域成立，本文在 Math500 上执行了冻结六臂探索（200 个数值可归一化任务，协议先提交后运行。面板定位声明：该面板从 398 个“纯数值可归一化”任务中选取，系统性排除了 102 个符号型/元组型/文本型答案任务，属探索性诊断面板；正式跨域主表面板为按答案类型分层抽取的 100 任务协议

（p3\_xdomain/P3\_MATH\_FINAL\_PROTOCOL.json，FROZEN\_BEFORE\_EXECUTION，含全宇宙评分器与发布评分分歧归档）。该正式面板已完成运行并复现塌缩：单体 large 54.0%、查询路由 50.0%、单体 medium 49.0%，三个 DAG 臂 13.0%—16.0%（静态对 large -39.0pp，CI [-50,-27]， $p \approx 0$ ；动态对静态 +1.0pp， $b=1/c=0$  无差异；有限候选 Oracle 64%）。值得注意的是正式协议采用了与探索版不同的分解接口（“JSON 计划→自由推理→校验”而非“数值事实→算术表达式”），在 Math500 的冻结分层面板上，两类已测试的中间产物式分解接口均出现明显性能退化（不外推到未测试的数学任务与分解接口）；阶段诊断显示损失分两层：给定计划的求解节点正确率仅 32%（medium 求解能力不足——冻结自财务域的阶段分配先验在此域失配，规划分解损失约 22pp），校验节点再把已答对的一半改错

（32%→15%，校验覆盖规则将最终答案推向更弱的 coder 模型）。以下探索性结果与正式结果方向一致，一并保留；三节点“数值抽取→表达式求解→数值校验”DAG 与财务域同构；失败检测全部为部署可得信号，运行时不使用标准答案；查询路由以冻结的面板中位 token 长度为阈值）。结果

（cross\_domain\_math/MATH\_ANALYSIS.json）：单体 large 63.5% 显著最优（有限候选 Oracle

69.5%)，查询路由 48.0%，单体 medium 37.0%；而三个 DAG 臂全部塌缩到 20.5%—21.5%，且代价更高（690—1,112 tokens）。三个预注册研究问题全部为负：分阶段分配劣于两个单体基线（RQ1 否定：-16.0pp 与 -42.5pp，均  $p < 10^{-4}$ ）；节点级分配劣于查询路由（RQ2 否定：-27.0pp， $p \approx 0$ ）；Dynamic-Real 相对 Static 无任何维度改善（RQ3 否定： $\Delta Q = -1.0pp$ ，CI [-4.5, +2.5]， $p = 0.79$ ；成本 +95.7 tokens、时延 +1.78s；预算违规 42/200；干预率 79.5%）。阶段诊断定位机制：抽取解析正常（193/200），但“数值事实 + 单条算术表达式”接口下求解值正确率仅 11.5%（表达式可执行率 54%）——多步数学推理所需的关系建模与代数变换无法被该接口表达，自由推理的单体模型因此占优；校验节点自由重算（21.0%）反而略好于受约束的表达式求解（11.5%）。**结论：财务域的 DAG 收益依赖“任务可分解为数值抽取 + 算术表达式”的接口条件；接口表达力不足时，分解、阶段异构分配与动态适应同时失效。**这与 5.2 分解基准的“拆分收益域依赖”一致，并将其推进为接口依赖；动态与静态在此无差异也再次印证能力/接口上限优先于调度策略的排序。该负结果按预注册协议原样保留，未做任何事后调整。

### 5.10 跨域正式验证：代码生成域（可执行接口与真实反馈）

代码域采用与财务域不同的自然节点接口：规划→代码生成→单元测试→修复/校验，其中单元测试是运行时反馈节点（语法错误、运行时错误、断言失败均为部署可得信号，全程不读取参考实现或正确性标签）。正式面板为 100 个 MBPP 任务（974 条记录中按 sha256 排序，确定性排除 4 组近重复对中的各一条与 2 个依赖未定义辅助函数的任务；与历史 14,650 条查询零重叠；协议 FROZEN\_BEFORE\_EXECUTION 先提交后运行，p3\_xdomain/P3\_CODE\_FINAL\_PROTOCOL.json）。六臂同构：单体 medium/large、查询路由（冻结长度阈值）、阶段分配（规划/生成/修复分阶段选模型）、静态 DAG（固定分配与固定回退，不因测试失败改变后续策略）、动态真实（按单元测试失败状态选择性修复/重路由，只更新失败节点及其后继，最大修复次数、token 与调用预算冻结）。结果（p3\_xdomain/mbpp\_run/RESULTS.json）：单体 medium 68.0%、large 76.0%、查询路由 71.0%、阶段分配 73.0%、静态 74.0%、**动态真实 80.0%**（有限候选 Oracle 87.0%）。配对对比：动态对静态 **+6.0pp，95% CI [+1.0, +12.0] 不含零**（Help/Harm = 7/1；McNemar 精确  $p = 0.070$ ，两种检验在 0.05 阈值上的分歧如实报告）；恢复率（初始失败→最终通过） $7/26 = 26.9\%$ ；修复共 49 次、干预率 27%；代价为动态 +95.7 tokens（+11.9%）且预算违规 22/100。该正向效应按冻结表述规范为方向明确的支持性证据：bootstrap 95% CI 不含零，但 exact McNemar  $p = 0.070$  未达 0.05 显著水平，两种配对推断口径不完全一致，故不宣称稳定统计显著，并以更高成本与预算越限为代价。其余对比均不显著：阶段分配对查询路由 +2.0pp（CI [-7, +11]），静态对单体 large -2.0pp，动态对单体 large +4.0pp（CI [-3, +11]）。

与 5.9 合读：数学域（探索性）中“数值事实 + 算术表达式”接口表达力不足，三个 DAG 臂塌缩且动态无效；代码域中节点接口天然可执行、单元测试反馈可靠，动态真实呈正向恢复效果（支持性证据：bootstrap CI 不含零、exact McNemar 未达 0.05 显著）。正式数学面板（分层 100，含与探索版不同的计划式分解接口）已完成并复现塌缩（单体 54% 对 DAG 13%—16%，静态对 large -39.0pp，CI 不含零），且阶段诊断把损失定位到冻结的阶段分配先验失配（求解节点 32%）与校验节点破坏

（32%→15%）。**跨域正反对照由此得到确认：接口表达能力不足时，分解、异构分配与动态适应同时失效（数学域，两类已测试接口族均如此）；接口可执行且反馈可靠时，反馈驱动的动态适应产生正向恢复（代码域）。本文的适用条件命题——多模型 DAG 协同的收益取决于阶段能力互补、节点接口表达能力和运行反馈质量三者同时成立——在正反两个方向上均有冻结协议证据。**代码域的负边界同样如

实：阶段分配未显著超过查询路由或单体 large，收益集中于“反馈驱动的修复”而非“阶段分工”本身；预算违规 22/100 表明  $1.2\times$  静态预算不足以完全约束动态修复开销，部署需收紧预算或上限。

表 5-14 跨域六臂对照总表

| 研究问题              | 财务域                        | MBPP（代码）                                       | Math500（数学）      |
|-------------------|----------------------------|------------------------------------------------|------------------|
| 阶段级异质性            | 有明确节点级差异                   | 有一定迹象，但未超过最强固定模型                               | 冻结先验明显失效         |
| Node vs Query     | 类型／阶段粒度更有效                 | +2.0pp, ns                                     | -37.0pp, 显著退化    |
| Dynamic vs Static | 主要体现选择性与资源效率               | +6.0pp; bootstrap CI 不跨 0, 但 McNemar $p=0.070$ | +1.0pp, ns       |
| 运行反馈              | 部署信号有限                     | unit test 为确定性反馈                               | parse／一致性无法覆盖值错误 |
| 主要边界              | capability／action coverage | 有效修复但成本上升、预算违规                                 | 先验与节点接口均失配       |

## 6 讨论

### 6.1 条件能力与传播能力的区别

阶段评测揭示的是给定输入条件下的模型表现。条件化推理任务提供标准事实，使推理者主要承担关系识别与表达式构造；实际传播链则还要求上游正确识别数值、实体、期间与单位。即使推理模型本身不变，输入来源变化也会改变其可解任务集合。因此，条件节点 Oracle 是能力分析工具，不能直接作为完整执行的可达质量。

跨模型矩阵为这一解释提供更直接的证据：固定 medium 或 coder 推理者，更换为 large 抽取后，最终质量提高。这说明同模型执行将不同阶段的强弱项绑定，可能使上游缺陷掩盖下游能力。DAG 的作用之一是使这种绑定可被打破。但现有矩阵尚不能识别输入质量变化的全部中介机制，也未证明每项组合差异均显著。尤其不能用不同任务集上的条件 Oracle 与传播 Oracle 之差，直接估计抽取噪声的因果效应。

### 6.2 单模型可预测性不等于最优模型可路由性

单模型成功预测与相对模型选择具有不同目标。前者要求区分该模型容易或困难的任务，后者要求在模型意见不一致的少量任务上识别谁更好。多个模型可能同时在简单任务成功、在复杂任务失败；这会为单模型分类器提供明显信号，却不给模型切换提供收益。

900 题画像中较高的成功预测 AUC 与未超过类型先验的路由质量并存，正体现了这一差别。AUC 对跨任务排序敏感，而路由收益还取决于同任务候选差异、评分可比性及切换错误的代价。类型先验与完整节点路由在独立节点确认面板上质量相同，也提示当前可稳定利用的结构主要是阶段差异，而不是细粒度实例表示。本文因此将贡献定位为阶段化分配及其执行接口，不把预测头的复杂程度或表示学习能力作为已获证明的优势。

### 6.3 选择性干预的作用与边界

强默认策略会使替代机会呈现不对称性：只有默认失败且替代者成功时覆盖才带来帮助，而覆盖默认已经正确的输出可能产生损害。限制干预范围有助于控制这种风险，但低覆盖率本身不是可靠性的充分条件；如果评分不能识别相对优势，少量切换也可能净损害。

Conf-200 的正向信号没有在 Conf-500 上复现，表明当前选择器尚未稳定识别可覆盖机会。合并开发语料上的风险—覆盖率曲线进一步显示，扩大干预范围会引入更多 Harm，但该曲线不能为未来数据指定一个已验证的安全阈值。二者共同支持保守选择的设计动机，同时保留剩余差距仍可能被更可靠特征和校准方法利用的可能性。

实验链现在可以把“分解—分工—适应”三层的价值分开计量：严格配对基准显示同模型拆分本身在 TAT-QA 上显著有害（-21.0pp）、MultiHiertt 上不显著（+6.0pp），而异构阶段分工在两域总体 +5.0pp 显著；多节点 DAG 上反馈条件化的动态控制在理想与真实检测下均显著超越静态。三层合读即是本文主线：**分解打开阶段解耦接口，异构分工兑现能力互补，动态控制安全且有预算地调用强恢复动作**。动态适应的价值随 DAG 结构深度显现。两节点链面板（48 与 250 任务）上动态第二版只给出方向一致但不显著的小幅正信号；而在含分支与汇合的四节点真实 DAG 上，同一族冻结适应规则带来 +20.0pp 的显著提升（CI 不含零，McNemar  $p \approx 1.9 \times 10^{-5}$ ），且 933 次适配调用全部限于失败节点及其后代闭包、分支隔离零违例、预算违规为零。两个信息合起来读：**选择性与预算约束下的动态适应，其收益与“失败能够局部化、受影响后代确实存在可利用替代”的结构条件成正比**——两节点链上可局部化的失败太少，四节点 DAG 上失败可以在分支、汇合与尾节点三个层面被选择性吸收。两臂对照消融进一步把归因说清：把静态对照的恢复目标同样换成升级 large，即可获得 +18.3pp（35.0%），策略逻辑超出目标选择的贡献仅 +1.7pp（不显著）——该面板的主要质量增益来自“失败节点升级至最强未试模型”这一动作；动态框架的可确证价值在于以选择性更新、预算约束与审计纪律安全地承载它。同时，把失败检测全部替换为部署可得信号后增益保留 91.7%，说明该收益不依赖 gold 失败信号，但部分依赖尾节点一致性检查在本面板近乎全触发的退化特性。因此动态适应的价值仍应表述为对后继决策范围的控制证据与 harm 控制，而非普适的质量保证：结论限于单一任务域。

### 6.4 能力覆盖与动作选择的不同上限

路由只能在候选执行结果之间选择。对于给定模型、提示、输入与动作集合，如果所有候选都失败，改进选择本身不能产生其中不存在的正确答案。这是固定候选集合的上限，不是对整个任务可解性的判断：更强模型、不同工具或新的输入表达仍可能改变候选集合。

真实失败集合中四个动作的成功并集较小，局部重规划也没有新增覆盖，因而当前剩余限制不能简单归因于动作选得不够好。结构解析诊断还提示，找到数值并不等于理解其关系。必要操作数出现在候选证据中，仍可能伴随实体绑定、期间对齐和表达式构造错误。该困难子集的证据支持把模型与动作覆盖列为主要瓶颈之一，但不足以断言所有任务只受推理能力限制。完整标准事实诊断的配对来源尚未核实，其缺失也限制了对纯推理失败比例的进一步量化。

### 6.5 资源约束与历史复用的作用层次

当前跨模型组合的平均资源开销接近，质量构成正常预算下的重要区分轴。这一事实不削弱资源约束的必要性：当剩余预算减少，额外调用是否可行会直接改变可恢复集合。预算响应面因此回答“已观测动

作在给定预算内覆盖多少失败”，而不回答“系统能否准确预测线上开销并保证不超时”。两者需要不同证据。

历史图复用解决另一类冗余，即相关追问重复处理未变化输入。它可以减少调用和 tokens，但不能自动纠正被复用的错误。当前图森林结果证明了特定修改型工作负载的局部重算机制，尚未证明多轮最终答案质量。把这类节省与单轮动态质量分开报告，有助于避免用资源指标替代正确性，也避免把缓存复用当作推理能力提升。

## 6.6 有效性限制

本文的上界、动态结果与诊断均有明确适用范围。第一，精确 Oracle 仅覆盖九种已枚举模型组合，完整动态策略空间没有求得全局最优。第二，动态真实调用实验规模有限，已用于开发分析，且失败检测读取评价答案，不能作为无理想反馈条件的在线验证。第三，条件节点、同模型传播、跨模型组合及失败恢复使用不同任务面板与估计对象，质量不可直接拼接。

第四，当前模型池存在大量共同失败，且成本和服务时间的异质性有限，结果未必迁移到能力跨度更大的模型池或不同硬件。第五，剩余差距路由的确认收益不稳定，合并语料后的交叉验证只提供事后机制解释。第六，困难子集的恢复与证据诊断存在选择偏差，部分历史结果缺少完整配对记录。第七，服务时间不包含全部启动、排队与调度开销，tokens 也不等同于货币成本。以上限制共同决定本文证据更适合支持阶段互补、执行边界与选择性适应的分析，而非宣称一个在所有复杂任务上全面占优的系统。

## 6.9 跨域负结果的机制含义

Math500 六臂对照给出三个预注册问题的全负结果，且失败被定位在接口层而非调度层：抽取正常、表达式可执行过半，但“数值事实 + 单条算术表达式”接口的求解正确率仅 11.5%，三个 DAG 臂塌缩到约 21%，而自由推理的单体 large 达 63.5%；动态与静态在塌缩区间内无差异。这为财务域的正结果划出明确边界：**DAG 化的收益条件是任务可自然表达为“结构化证据抽取 + 确定性可执行计算”，当接口本身丢失完成任务所需的表达能力时，分解、异构分配与动态适应会同时失效——能力/接口上限对调度策略的优先序在两个方向上都被观察到。代码域的正式跨域实验（100 任务冻结协议）给出了这一边界假设正方向的初步支持：以单元测试为可执行接口与部署反馈，反馈驱动的动态 DAG 相对静态 +6.0pp (CI [+1.0,+12.0]，恢复率 26.9%，Help/Harm 7/1)，而阶段分配本身未显著超过查询路由；其代价是 +11.9% tokens 与 22/100 的预算越限。与数学域的塌缩合读（正式分层-100 面板已复现：单体 54% 对 DAG 13%—16%，且两类已测试分解接口族在该面板上均明显退化，校验节点还会破坏已正确的解）：**接口表达能力决定 DAG 是否可用，反馈可靠性决定动态适应是否有东西可利用，而阶段分工的额外收益即使在接口良好的域也未达显著——三层条件的分离是本文跨域部分的中心结论，正反两侧均有冻结协议证据。## 7 结论****

本文研究复杂任务中的异构大模型协同执行，提出反馈感知的自适应 DAG 路由框架，以能力画像支持节点级分配，以反馈条件化的后继适应连接静态执行与动态调整，并通过剩余预算控制和历史图复用约束额外开销。动态适应不以修改拓扑为必要条件；模型重新分配、受影响后继更新与有限恢复均属于其执行范围。

实验支持阶段级互补真实存在：冻结节点路由相对查询路由提高约 6.9 个百分点，主要增益可由类型先验解释。跨模型传播进一步表明，上游来源能够改变下游能力的表现，独立分配阶段模型可以解除同模

型链的能力绑定。然而，单模型成功的可预测性没有转化为稳定的剩余差距路由收益，较大确认集也未复现较小确认集的正向信号。动态适应的价值在两节点链与多节点 DAG 上呈现梯度：两节点链上为方向一致但未确证的小幅正信号（48 任务 +2.1pp、250 任务冻结确认 +2.8pp，CI 均覆盖零）；在含分支与汇合的四节点真实 DAG 上，选择性动态适应显著优于静态执行（+20.0pp，CI 不含零，Help/Harm 28/4），933 次适配调用全部限于受影响后代、分支隔离零违例、预算违规为零。消融归因表明主要增益来自失败节点升级至最强未试模型的动作（同目标静态对照已达 35.0%），部署可得的解析/执行与一致性检测可保留其中 91.7%——动态收益不依赖理想失败检测，其框架价值在于安全、选择性且可审计地承载该动作；结论仍限于单域面板。

多模型协同的关键是识别不同执行阶段的能力互补，并在可靠证据和资源约束下进行选择性的节点分配与动态调整。与此同时，模型池及动作集合必须包含可利用的正确候选；困难共同失败任务上的选择优化，不能替代能力覆盖的扩展。

这些结论受限于枚举的  $3 \times 3$  组合空间、尚未优化的完整动态策略空间、大量共同失败、有限的成本与时延异质性、不稳定的剩余路由泛化，以及困难子集上较低的恢复覆盖。未来可研究更强且更异质的模型、扩展现有确定性执行器的符号与程序能力、更丰富的工具支持和证据推理、更可靠的选择性覆盖，以及更大动态策略空间中的近似最优决策。这些方向不属于本文已经完成并验证的机制。

## 参考文献

- [1] Ong, I., et al. RouteLLM: Learning to Route LLMs with Preference Data. 2024. arXiv:2406.18665. 原文.X
- [2] Chen, L., Zaharia, M., and Zou, J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance. 2023. arXiv:2305.05176. 原文.
- [3] Kim, S., et al. An LLM Compiler for Parallel Function Calling. 2024 年修订版, arXiv:2312.04511v3. 原文.
- [4] Madaan, A., et al. Self-Refine: Iterative Refinement with Self-Feedback. 2023. arXiv:2303.17651. 原文.
- [5] Wang, Z. Z., Mao, J., Fried, D., and Neubig, G. Agent Workflow Memory. 2024. arXiv:2409.07429. 原文.
- [6] MultiHiertt: Numerical Reasoning over Multi Hierarchical Tabular and Textual Data. ACL 2022. 正式论文页面.
- [7] TAT-QA: A Question Answering Benchmark on a Hybrid of Tabular and Textual Content in Finance. ACL-IJCNLP 2021. 正式论文页面.