

面向复杂任务的反馈感知多模型自适应有向无环图路由

第一版证据重构稿，2026 年 9 月 20 日。方法名称保留为 Feedback-aware Adaptive DAG Routing。所有章节、节标题采用中文。方括号证据编号对应同目录 PAPER_EVIDENCE_MAP.md。各章“待我确认项”为审阅批注，投稿前移除。本文不将真实调用自动等同于可部署在线评价。

摘要

复杂任务往往同时包含事实抽取、关系推理与结果验证，不同节点的能力需求使单次查询级模型选择难以充分利用模型池的异构性。然而，增加分解、重试或模型切换也不必然改善最终答案，其收益受到上游证据、失败判据和剩余资源的共同约束。本文提出反馈感知的多模型自适应有向无环图路由框架，以质量、成本和时延画像支持初始节点分配，在执行过程中记录反馈，通过选择性后继调整与预算感知恢复更新执行策略，并利用版本化历史图支持多轮复用。本文将动态执行定义为反馈条件化的后续策略调整，而非必须重写图拓扑。基于 MultiHiertt 和 TAT-QA 的分层评价显示：在 100 任务、493 个主要节点的条件化确认面板上，冻结节点路由的平均质量为 0.5355，相比查询路由提高 6.90 个百分点；类型先验取得相同平均质量，表明增益主要来自路由粒度。在已分析的 48 任务真实调用面板上，动态第二版与静态策略分别完成 26 和 25 个任务，差异不显著，但观察到的帮助/损害由第一版的 2/1 变为 1/0。该实验采用理想失败检测，不能作为完全在线闭环的证据。对 148 个候选失败节点重新审计后，仅 116 个对应原最终答案错误；固定四类恢复动作的覆盖为 8/116。历史图在 20 个修改型追问中减少 50% 的逻辑调用需求，但尚未证明最终答案质量。结果支持节点粒度与受约束反馈调度的价值，同时表明动态策略只能利用当前候选动作中已存在的互补机会，不能保证恢复共同失败的任务。

关键词：大模型路由；节点能力画像；有向无环图；反馈驱动执行；预算感知恢复；历史图复用

待我确认项： 动态真实调用结果保留理想失败检测限定；摘要不使用旧稿中未经审计的高恢复率。

1 引言

1.1 研究背景与动机

大语言模型（Large Language Model, LLM）的能力与执行开销存在差异。对复杂请求而言，这种差异不仅发生在完整问题之间，还可能发生在同一问题内部：从长材料中提取数值、确定比较关系、形成运算表达式以及验证结果分别要求不同能力。将完整任务交给单一模型，使所有步骤共享同一能力结构；即使任务总体相似，关键步骤也可能具有不同的适配模型。

查询级路由为模型选择提供了有效接口，但复杂任务的执行还有两个额外因素。首先，前驱输出决定后继输入，局部错误能够沿依赖关系传播。其次，任务进行到中途时，原有资源预算已部分消耗，新的选择必须同时考虑当前状态和剩余资源。只优化初始选择，不能表达这些变化。显式有向无环图

（Directed Acyclic Graph, DAG）使中间结果、依赖与模型分配成为可检查对象，为运行中的反馈调度提供基础。

然而，显式分解和动态调整本身具有成本。额外节点可能增加错误接口；重试可能重复相同输出；切换模型也可能破坏原本正确的结果。因此，本文不以更多执行步骤作为方法有效性的代理，而分别检验节点分配、失败恢复、错误传播和多轮复用的收益及边界。

1.2 研究问题

本文研究：在复杂任务的 DAG 执行过程中，系统如何依据离线模型画像建立初始分配，并结合执行反馈调整受影响的后续策略，在质量、成本与时延约束下完成多模型协同？这一问题包含三项相互关联的判断：何种粒度能够利用能力差异；何时值得改变既有计划；何种历史结果能够在新请求中继续使用。

评价这些判断必须区分预测质量与任务成功、节点缺陷与最终失败、真实模型调用与真实在线决策。若恢复仅在评价答案判错时触发，则模型输出虽来自真实调用，调度器仍获得了实际部署中不可用的信息；若一个被标为证据缺失的节点对应正确最终答案，再次答对不能算作恢复。本文将这些信息边界纳入实验设计与结果解释。

1.3 方法概览

框架沿“模型能力画像—控制路由—任务分解—初始图—静态或动态执行—历史图复用—多目标决策”组织。离线画像描述候选模型的预期质量和资源开销；任务分解产生带有输入输出约定的节点；初始路由为各节点分配执行模型。静态策略保留后继计划，允许在当前失败节点执行预定义局部回退。动态策略依据反馈状态选择性地调整受影响后继的模型和恢复安排，并在预算不足时停止升级。

反馈记忆记录模型在特定状态下的表现，历史图则保存具体任务的依赖、输出及版本。前者服务于后续选择，后者减少重复执行。多目标决策贯穿这些环节，以共同的质量、成本、时延口径比较可行策略，而不额外提出新的通用优化算法。

1.4 主要贡献

第一，构建基于类型化任务节点的多模型路由框架，并通过冻结确认和类型先验消融定位增益来源。实验支持节点粒度的有效性，不支持学习式问题表示在所有域上稳定优于类型先验。

第二，给出反馈条件化的动态执行实例，将局部恢复、后继调整与剩余预算联系起来，并通过真实调用、受控故障和失败判据审计识别其适用边界。最新动态策略的主要证据是观测到更少的负迁移，而非显著的总体准确率优势。

第三，将版本化历史图复用与质量—资源权衡纳入同一执行框架。现有实验证明特定追问负载下的复用与调用节省机制，并以固定恢复输出上的预算响应面展示资源约束如何限制可利用的恢复机会。

待我确认项： 本文以受约束执行框架和机制证据作为贡献，不以学习式路由器、拓扑搜索器或新多目标算法作为已证实贡献。

2 相关工作

2.1 大模型路由与模型能力画像

RouteLLM 利用偏好数据学习查询到候选模型的选择，并评价质量与成本权衡。[1] 本文与其共享通过预测能力分配模型的目标，但选择对象为同一任务内部的类型化节点，且进一步研究执行后状态变化。节点基准的正差距并不意味着该差距一定可由问题编码预测，因此本文保留类型先验和事后最优选择作为不同参照。

FrugalGPT 研究通过模型调用策略降低开销并维持质量。[2] 本文同样关注有限资源下的选择，但将资源状态放在具有依赖关系的执行链中：一个恢复动作既消耗剩余预算，也改变后继输入。该区别是研究对象的细化，不构成对既有路由方法全面失效的判断。

2.2 任务分解与依赖图执行

LLMCompiler 将规划、任务分发与执行分开，利用依赖结构组织函数调用，并包含动态重新规划机制。[3] 本文借鉴显式依赖使执行过程可检查的组织思想，关注不同 LLM 在节点上的分工，以及失败后是否存在值得利用的替代能力。实验使用有限财务任务模板和小型链式图，不能据此宣称通用规划能力，也不将串行服务时长解释为并行图调度加速。

任务分解能够暴露中间接口，也增加接口错误和证据遗漏的机会。本文因此将整题作答与 DAG 比较、复杂度分层和结构指标放在同一分析中，检验分解何时有益，而非预设分解必然改善推理。

2.3 反馈驱动的自适应执行

Self-Refine 通过反馈与修订迭代改进生成结果。[4] 本文关注的反馈作用对象包括执行模型、局部恢复动作与后续计划，除了输出修订，还需要处理依赖失效和资源消耗。本文也将反馈信号的可靠性作为实验变量：标准答案可以支持离线判定，却不能等同于在线可得反馈。

因此，本文对反馈驱动执行的补充主要在于明确调度和评价边界。相同提示的重试、使用新提示的再次生成，以及根据金标准筛选正确候选，是不同操作，应分别记录和解释。

2.4 多目标执行与历史记忆

Agent Workflow Memory 从历史经验中形成可复用工作流程，为后续任务提供执行指导。[5] 本文的图森林重点保存具体任务的输入输出、依赖和版本，通过显式修改定位需要重算的部分。当前实现并不等同于通用语义 workflow 检索，也没有充分验证大规模图剪枝。

质量、调用成本与时延的权衡可通过约束优化和非支配关系表达。本文采用这些已有决策概念比较有限策略，主要考察约束如何改变恢复机会，以及复用如何减少资源需求，不将采用帕累托准则本身作为算法创新。

待我确认项： 项目中找到相关工作草稿，但未定位用户提到的参考文献原文附件；本版书目信息来自已核验的原论文页面。若另有指定论文，应在定稿时替换结构参照，不能声称本版已阅读这些未定位附件。

3 方法

3.1 框架概览

设用户任务为 x 、材料为 D 、候选模型池为 M 。系统构造初始图 $G_0=(V_0,E_0)$ ，获得初始分配 π_0 ，并维护状态 s_t 、反馈记忆 H_t 与历史图集合 F_t 。一次执行决策使用当前可见输入、历史反馈和剩余预算，输出下一执行节点及其执行者。该过程表示为

$$(x, D) \rightarrow G_0 \rightarrow \pi_0 \rightarrow (y_t, s_{t+1}, H_{t+1}) \rightarrow (G_{t+1}, \pi_{t+1}) \rightarrow F_{t+1}.$$

其中，图结构可以保持不变；动态性来自后续策略依赖新的反馈。模型负责语义理解、关系生成和验证，已有确定性执行器负责表达式求值。系统不将可由程序精确执行的算术反复交给模型生成。

3.2 模型能力画像

对类型为 τ_i 的节点 v_i 和模型 m ，画像描述预期质量、tokens 与服务时长：

$$\hat{Q}(i, m), \hat{C}(i, m), \hat{L}(i, m).$$

质量由开发集节点评分估计。学习式实例采用冻结的问题编码 $e(x)$ 、类型独热编码和问题长度特征：

$$\phi_i = \begin{bmatrix} e(x) \\ \text{type_one_hot} \\ \text{length} \end{bmatrix}$$

各模型的 Ridge 回归头在开发数据拟合，正则系数固定为 1。类型先验实例直接使用开发数据中各类型的平均质量选择模型，作为不依赖问题表示学习的对照。现有成本与时延预测使用模型级开发均值，不将其描述为已经训练的状态条件化资源预测器。

3.3 任务分解与初始依赖图

图中节点定义为 $v_i=(\tau_i, I_i, O_i, Pa(i), K_i)$ ，分别记录职责、输入约定、输出约定、直接前驱和约束。边表示数据依赖，只有前驱产生可用输出后节点才能执行。主要职责为抽取、推理、验证和汇总；自然出现的转换节点作为探索性类型保留。

当前财务实例以领域模板构造抽取—推理—验证流程。抽取结果提供带索引的事实，推理生成引用事实的表达式，执行器求值，验证节点检查一致性。用于节点能力测量的条件化基准可以提供标准事实；真实传播实验则使用前驱实际输出。两类输入条件不能混合解释。

分解本身是待检验的执行选择。更细粒度能够暴露错误位置，却可能增加调用次数，或丢失整题生成中可利用的上下文。本文不以节点数量作为分解质量，也不将目前模板实现写成通用自由文本规划器。

3.4 节点级路由与静态分配

查询级路由 $r_q: x \rightarrow m$ 为整题选择模型；节点级路由 $r_n: (x, \tau_i) \rightarrow m_i$ 允许同一任务使用不同执行者。初始选择为

$$m_i^* = \arg \max_{m \in M} \{ \alpha \hat{Q}(i, m) - \beta \hat{C}(i, m) - \gamma \hat{L}(i, m) \}.$$

节点确认实验固定使用 $U = \hat{Q} - 0.05\hat{C}/1000 - 0.05\hat{L}/10$ ，其中成本以 tokens、时长以秒计。候选预测及最终分配均保留。确认集不参与重新训练或调参；后续评分器修订也不改变已经冻结的路由选择。

静态执行在初始分配后保持后继计划不变。在最新静态—动态比较中，静态策略允许预定义局部回退；回退结果可以传播给后继，但后继执行模型仍按原计划。因此，静态不是“完全没有恢复”，动态优势也不能简单归因于多一次调用。

3.5 反馈记忆

系统维护 $H_t = \{(v_j, m_j, s_j, r_j)\}$ ，记录已执行节点、模型、状态及结果。记忆不包含未调用候选的当前质量标签。早期实例以类型、问题长度分桶与模型作为键，用成功次数 S_k 和观测次数 N_k 形成平滑统计 $p_k = (S_k + 1) / (N_k + 2)$ ，并与冻结质量估计融合：

$$\tilde{Q}_t(i, m) = (1 - \eta) \hat{Q}(i, m) + \eta p_{k(i, s_t, m)}.$$

初始选择与恢复状态使用不同记忆路径，既有实例分别采用 0.3 和 0.5 的融合系数。反馈第二类实例使用模型失败计数修正能力排序。这些都是固定低容量规则，不引入新的在线训练模块。

记忆改善的是未来决策依据，不自动修改 DAG。反馈是否正确则是独立问题：离线评分生成的成功事件具有理想化条件，验证器判断只能作为有噪声观测。本文在实验中分别报告这些条件。

3.6 动态依赖图调整

3.6.1 反馈状态更新

状态包括已执行节点、实际输出、失败事件、候选模型使用历史及剩余资源。某节点输出变化后，只评估依赖其结果的后继；不受影响的结果继续有效。动态执行定义为反馈条件化的后续调整，可以改变模型、恢复和验证安排，也可以在局部分解时改变结构，但不要求每次都改变拓扑。

3.6.2 真实失败判定与信息边界

本文区分运行时异常与离线真实失败。前者来自格式错误、执行器异常或验证器拒绝；后者指原最终答案未满足评价标准。两者并不等价。以正确性 Y_0 表示恢复前最终任务状态，则真实失败集合为 $S_{\text{fail}} = \{j: Y_{0j} = 0\}$ 。恢复质量只在这一集合上统计。

实现与评价还需分离 runtime snapshot 和 offline label payload。运行快照仅包含问题、材料、实际父节点输出、实际抽取事实及失败状态；答案、程序和 required operands 只供离线分类、证据召回与评分使用。找不到真实抽取输出的样本不能用标准事实补齐，应标为无效快照。标准事实条件下的历史实验单独标注。

当前 48 任务动态试验通过标准答案比较触发推理回退并更新失败计数，因此是理想失败检测条件下的真实执行。该实现界限不改变调度规则的定义，但限制其部署性结论；本文不声称已经实现可靠的在线真实失败识别。

3.6.3 节点级恢复

固定动作集包括同模型再次调用、切换模型、重新抽取证据和局部分解。各动作基于相同运行快照，新增 tokens 和服务时长分别累计。重新抽取不接收 required operands；证据召回变化由离线评价器计算。

局部分解以子图替换当前职责，将事实语义对齐、关系表达和确定性计算分离。结构改变必须保留原接口需要的输出。接口语言允许的常数或运算符也必须统一，否则无法区分分解收益和执行器修复收益。本文保留这些恢复动作，但不根据失败标签预设最优动作，也不把相同提示的确定性重试视作必然有效。

3.6.4 选择性后继重调度

第二版动态策略采用五项约束。其一，在尚无相反失败证据时保护已有回退选择，避免一次全局更新推翻原计划。其二，只有输出发生实际变化或节点失败影响依赖时才重新评估相关后继。其三，优先处理影响最终结果的关键节点；现有证据主要来自两节点链的最终推理节点，不包含通用关键路径优先级学习。其四，使用类型能力排序及历史失败计数修正候选分数：

$$S_i(m|\tau) = \text{rank}(m|\tau) - \lambda_f N_{fail,t}(m, \tau).$$

替换需要满足预设差距，避免无充分依据的频繁切换。其五，后续恢复受预算约束。当前实例以固定排序、失败计数和差距 0.1 实现这些规则；“正证据保护”在实现上主要体现为保留尚未失败的既有候选，而非已校准的成功概率保证。

受影响范围可写为 $A_t \cup \text{Desc_G}(A_t)$ 。这一集合说明依赖边界，但目前小型链的实验证据不足以证明一般大图上的全局重调度效果。选择性策略是否更安全，应通过 Help/Harm 和最终质量检验，不能仅凭调用更少推断。

3.6.5 预算感知升级与终止

设初始 token 和时间预算为 B_0 、 T_0 ，已发生开销为 c_j 、 ℓ_j ，则

$$B_{rem} = B_0 - \sum_j c_j, T_{rem} = T_0 - \sum_j \ell_j.$$

恢复动作必须满足剩余预算中的可行性要求。不足以启动恢复时终止；低成本动作失败且仍有资源时允许升级到更昂贵动作。现有动态实现使用最小剩余 token 门控，不能据此宣称具有精确的调用前成本预测。

预算响应面进一步用已记录动作的实际开销进行离线约束回放。它回答固定结果集合在不同剩余资源下的可达质量，而非验证部署时能够预知时延和成功。真实部署所需的开销预测误差处理未在本轮实验中得到完整证明。

3.7 历史任务图复用

图森林 $F = \{G_1^{(v_1)}, \dots, G_k^{(v_k)}\}$ 保存历史 DAG 及其版本。节点记录输入、输出、模型、依赖、执行反馈与可用资源信息。新追问通过检索相关图、识别有效结果、修改输入并重算受影响部分完成。

若直接变更节点集合为 ΔV ，则失效候选为 $\Delta V \cup \text{Desc_G}(\Delta V)$ ，其余节点仍需满足原输入和约束未变的条件才能复用。修改计算假设不等于修改源材料：前者可保留原始抽取，后者需要使相关抽取失效。版本保留使结果能够追溯到具体输入条件。

当前原型使用显式任务标识和事实依赖，不宣称已经实现通用语义图检索。图剪枝属于尚未充分验证的设计范围，不作为本稿实证贡献。

3.8 多目标决策

对候选执行方案 p ，评价向量为 $z(p)=(Q_p, C_p, L_p)$ 。质量最大化，成本与时延最小化。单目标约束形式为 $\min C_p$ ，满足 $Q_p \geq Q_{\min}$ ；双目标保留质量—成本非支配方案；三目标同时加入时延。

若 p_a 在三项指标上均不劣于 p_b ，且至少一项严格更好，则 p_a 支配 p_b 。有限候选的非支配集合用于呈现不同偏好下的选择，不声称全局最优。不同工作负载、条件化节点分数与最终任务成功率不能混成一个帕累托集合。事后最优选择只表示诊断上界，不与可部署策略共同争夺“最优方法”。

待我确认项：当前动态实现仍借助评价答案触发部分动作；关键节点优先仅在小型链上实例化；双预算响应面是离线分析。上述内容已在方法中限定，未补造新模块。

4 实验设置

4.1 数据与证据层级

实验使用财务表格与文本问答数据 MultiHiertt[6] 和 TAT-QA[7]。数据子集对应不同研究问题，不汇总为一个总测试集，也不把重复使用的任务当成新增独立样本。

表 4-1 实验面板与证据层级

实验部分	样本单位与数量	评价条件	主要用途
节点路由开发	201 任务、372 节点	开发数据与任务分组交叉验证	拟合画像、类型消融
冻结节点确认	100 任务、493 主要节点；另 4 个转换节点	经使用记录审计的 MultiHiertt train 子集；条件化节点评价	冻结选择的泛化
跨域节点分析	TAT-QA 40 任务、200 节点	条件化节点面板	类型先验与学习式方法比较
静态—动态回放	100 任务	既有候选输出回放	调度机制检查
静态—动态真实调用	48 任务	已分析面板，真实输入传播、理想失败检测	最新动态版本比较
受控故障	33 任务候选，形成 118 个配对条件	开发层真实调用，含无故障对照	错误传播机制
恢复矩阵	原 148 节点，审计后 116 节点、96 个任务	固定快照动作调用及离线评分	真实失败恢复
历史图复用	20 个修改型追问	历史输出复用与新调用	多轮资源收益

节点确认集来自有标签 train split；官方 test 缺少本实验需要的答案和程序，因此未作为有监督确认集。使用记录审计仅覆盖当前工作区，不能证明预训练数据无交集。48 任务动态面板此前已被分析，不称为未经触碰的独立测试集。

4.2 模型池与表示

路由池固定为 medium: Qwen2.5-7B-Instruct, large: Qwen2.5-14B-Instruct-GPTQ-Int8, coder: Qwen2.5-Coder-7B-Instruct。R1 只出现在早期旁路诊断, 不进入主路由池。问题表示来自冻结 GTE-Qwen2-7B-instruct; 各质量头、类型定义和静态效用在确认前封存。

模型规模和量化方式不同, tokens 因而只表示调用量代理, 不能等同于真实货币费用或 GPU 能耗。资源比较以相同实验环境内的记录为准。

4.3 对照方法

路由对照包括全局最佳固定模型、Always Large、查询路由、类型先验、冻结节点路由和节点事后最优选择。类型先验依据开发类型均值选择; 节点 Oracle 使用当前评价标签逐节点取最大值, 仅作为上界。早期 Static Capability 为全局画像策略, 与后期类型先验定义不同, 本稿不混用名称。

执行对照包括允许局部回退的静态计划、第一版动态策略和选择性动态第二版。恢复部分固定比较四种动作及其顺序组合; 局部子图重规划单独作为已完成的负结果分析。图复用与单轮执行分别评价, 不将复用成功率计入单轮答案正确率。

4.4 指标与统计

节点质量 Q 为节点对应评分均值, 任务成功率为最终答案正确比例。Help 计数静态错而动态对, Harm 计数静态对而动态错。真实失败恢复率定义为

$$R = \frac{\sum_j 1(Y_j^{static}=0, Y_j^{new}=1)}{\sum_j 1(Y_j^{static}=0)}.$$

净增益除以静态失败数等于 (Help-Harm)/N_fail, 与上述恢复率不是同一指标。成本记录输入与输出 tokens; 时延默认指请求服务时长之和。含模型装载、排队和调度的端到端墙钟时间必须另行标识。

证据召回 ER 为运行事实覆盖的 required operands 比例, 仅离线计算。复用率为可复用逻辑节点占需处理节点的比例; 调用减少率与 token 减少率使用明确基线。预算遗憾为同一预算下动作 Oracle 覆盖与策略恢复质量之差, 不与整体任务准确率混用。

统计按任务配对或聚类重采样, 避免同任务多节点被视为独立。新版矩阵的论文复核使用固定种子 20260920、10,000 次任务聚类 bootstrap, 按节点加权均值重新计算差异区间; 原文件统计保留原协议。本文将复核统计标为事后离线汇总, 不冒充原预注册分析。区间包含零的比较均不宣称显著。

4.5 实现与版本控制

主采集使用本地模型服务, 基础设置包括 temperature=0、top_p=1、最大输出 512 tokens。节点确认按共享请求去重, 每模型 404 次、三模型共 1,212 次; 逻辑节点数不等于请求数。后期动态执行按模型加载并复用已存响应, 其服务时间不能解释为完整在线用户等待时间。各子实验保留自身冻结协议, 不强行套用统一并发或统一时延口径。

评分采用扩展执行器矩阵 SCORED_MATRIX_EXEC.npz，保留已经冻结的模型选择。旧 RESULTS.json 的部分质量数值未同步更新，不能直接拼入新表。新版 Oracle 必须在新版 Q 矩阵上重新最大化，得到 0.6065；沿用旧 Oracle 选择再重评分得到的 0.6045 不是新版严格上界。[E01]

待我确认项： 投稿复现信息仍需补齐各批次硬件与服务软件版本；当前文件不足以支持统一硬件声明。复杂度分层表缺少逐任务标识和独立生成脚本，按探索性记录处理。

5 实验结果与分析

5.1 能力异质性与路由机会

本实验检验同一模型是否在各类节点上始终占优。使用冻结确认面板中的 493 个主要节点，对三模型实际输出按新版统一执行器评分，比较类型内模型质量与逐节点 Oracle。[E01]

表 5-1 节点类型内的模型能力差异

节点类型	节点数	medium	large	coder	节点 Oracle	相对类型最佳固定模型的差距
抽取	193	0.3731	0.5959	0.3782	0.6943	9.84 个百分点
推理	100	0.3100	0.2500	0.3100	0.4100	10.00 个百分点
验证	200	0.5200	0.4550	0.5900	0.6200	3.00 个百分点

抽取以 large 最好，推理中 medium 与 coder 并列，验证以 coder 最好。这说明按照完整任务固定一个模型会忽略类型差异。抽取和推理的类型内 Oracle 仍高于最佳固定模型，表明类型先验之外也存在个体互补机会。

全局 Always Large 的质量为 0.4686，逐节点 Oracle 为 0.6065，差距为 13.79 个百分点。该全局差距同时包含类型间和类型内机会，不能全部归因于问题表示能够学习的信号。Oracle 依赖事后标签，不是可部署路由器。结论是节点粒度值得研究，而非查询级方法在所有场景均无效。

5.2 节点级模型选择

为检验机会能否转化为实际选择收益，比较开发阶段封存的查询路由和节点路由，并加入仅使用开发类型均值的类型先验。质量按新版矩阵计算；tokens 与时长沿用相同冻结选择的去重任务调用口径。[E01—E02]

表 5-2 冻结节点路由的质量与资源比较

方法	节点平均质量	相对查询路由	每任务 tokens	每任务服务时长总和（秒）
Always Large	0.4686	+0.20 个百分点	4,991.02	11.71
查询路由	0.4665	—	4,985.33	10.19
类型先验	0.5355	+6.90 个百分点	本稿未单独汇总	本稿未单独汇总
冻结节点路由	0.5355	+6.90 个百分点	4,856.43	7.79
节点 Oracle	0.6065	+14.00 个百分点	不作可部署成本比较	不作可部署时延比较

节点路由相对查询路由的配对质量差异为 6.90 个百分点，事后复核 95% 区间为 [3.44,10.61]，不包含零；节点路由相对类型先验的差异为零，区间为 [-1.21,1.21]，差异不显著。前者同时减少约 2.59% 的任务 tokens 和 23.54% 的服务时间总和。时延下降是同一采集环境中的资源观测，不表示在不同部署条件下保持相同比例。

开发消融和跨域结果进一步限制贡献归因。

表 5-3 类型先验与问题表示消融

面板与评分版本	查询路由	类型先验	学习式节点方法	解释
开发消融，原评分	0.3952	0.4543	0.4704	类型先验贡献主要增量；节点表示另增约 1.61 个百分点
MultiHiertt 确认，新版评分	0.4665	0.5355	0.5355	节点表示未超过类型先验
TAT-QA 节点分析	0.6100	0.6300	0.6100	完整学习式版本相对类型先验差异不显著

TAT-QA 的差异区间为 [-5.5,1.5] 个百分点。[E03] 不同面板的特征与评分版本已在表中区分，不能据此作严格跨域难度排序。实验支持“将选择对象下降到类型化节点”的贡献，不支持“学习到普遍优于类型先验的节点表示”。

5.3 任务分解与结构质量

本节检验显式分解是否必然改善最终答案。首先在有匹配整题作答记录的任务上比较整题生成与 DAG，避免直接比较样本量不同的全量均值。[E04]

表 5-4 整题生成与依赖图的配对比较

数据集	配对任务数	整题正确率	配对 DAG 正确率	配对差异及原记录 95% 区间
TAT-QA	160	52.50%	43.13%	-9.38 个百分点 [-17.5,-1.3]
MultiHiertt	50	8.00%	22.00%	+14.00 个百分点 [2.0,26.0]
两者配对汇总	210	41.90%	38.10%	-3.81 个百分点 [-10.5,3.3]

配对 DAG 数值由同一文件中的整题均值与配对差异恢复，不使用不同样本量的 DAG 全量均值。TAT-QA 上分解表现较低，MultiHiertt 上较高，汇总差异不显著。该结果与“分解总有益”不一致，也表明不能只选择一个有利数据集证明方法。

这些实验具有重要输入限制。历史 TAT-QA 采集部分使用真实抽取，解析失败存在标准事实回退；MultiHiertt 的 50 个配对样本取自标准输入条件下的节点结果，不能将该配对优势视为真实抽取链优势。因此表中比较是既有协议下的分解效用证据，不是两域均完全无金标准输入的部署评价。

项目另有 260 条复杂度分层记录，以程序运算数作为离线复杂度代理。其合并描述统计如下。[E05]

表 5-5 复杂度分层的探索性记录

运算复杂度	记录数	整题正确数	DAG 正确数	描述性差异
1—2 步	196	75	62	-6.63 个百分点
3 步	40	19	23	+10.00 个百分点

运算复杂度	记录数	整题正确数	DAG 正确数	描述性差异
至少 4 步	24	2	7	+20.83 个百分点

低复杂度任务可能不需要额外接口，而复杂推理可能受益于显式中间步骤。但此分层文件没有逐任务标识，样本数也与前表配对集合不同；高复杂度仅 24 条，并混合领域及输入条件。故这一趋势只支持探索性解释，不能宣称复杂度与收益存在已确证的单调因果关系，也不能把金标准程序复杂度用于声称已实现的在线分解决策。

结构质量分析进一步比较覆盖、依赖有效性、可执行性与原子性。在 100 条分析记录中，最终正确为 9 条。[E06]

表 5-6 结构指标与最终正确性关联

指标	与最终正确性的相关系数	解释范围
覆盖	0.377	很大程度受所需事实是否存在影响
依赖有效性	0.290	反映中间引用和结果连接是否成立
可执行性	0.281	反映表达式或局部流程可否执行
原子性	0.078	当前指标与正确性关联较弱

覆盖关联最高，却不能等同于分解算法质量：如果上游事实已经缺失，再清晰的子图也可能无法恢复答案。相关性本身不证明因果。由此，分解收益应与证据条件、领域结构和执行接口共同解释。

5.4 反馈学习与失败判据审计

反馈实验首先检验历史执行信息能否改变后续选择。在条件化节点输出上，静态节点路由、初始反馈版本与状态感知版本使用相同基础候选记录。[E07]

表 5-7 条件化反馈回放结果

策略	新版节点质量	相对静态差异	调用倍率
静态节点路由	0.5355	—	1.000
初始反馈版本	0.5355	0	本表不单独解释
状态感知反馈版本	0.5822	+4.67 个百分点	1.460

原分析保存的任务聚类区间为 [2.6,6.8] 个百分点，指向正增益；它与本稿节点加权复核区间采用不同汇总细节，不能混用。该实验使用可评分结果构造反馈并允许恢复，既改变模型选择，也增加执行机会。因此结果支持反馈与恢复组合在理想化条件下的潜力，不能把全部提升归因于记忆学习，更不能直接当成真实传播任务成功率。

随后对恢复候选做最终答案审计，检查“被标为失败的节点是否确实对应错误任务”。[E08]

表 5-8 失败候选的最终答案审计

离线失败类型	原候选数	原最终答案已正确	原最终答案错误
证据类	61	16	45
推理类	61	13	48
结构类	26	3	23

离线失败类型	原候选数	原最终答案已正确	原最终答案错误
合计	148	32	116

32/148 个候选的原最终答案已经正确。原记录中 34 个“重试成功”有 32 个落在这些样本上；剩余 2 个真正由错转对的案例来自提示发生变化的调用，不能作为同提示、零温度重试有效的证据。语义审计还发现，MultiHiertt 子集的 79 次重试均未保持原提示一致；TAT-QA 69 次保持提示一致，其中 66 次输出完全相同。[E09]

历史分解结果也受到输入条件影响：可定位的 40 条记录在标准事实下成功 13 条，其中仅 1 条能在实际抽取事实下确认仍成立，4 条答案错误、2 条发生索引错误，另 6 条没有真实抽取记录，不能完成同条件重评。[E10] 本稿据此撤回“31.7% 端到端恢复率”的旧表述，保留事实条件对局部恢复的限制。

本节结论是：反馈有利用执行经验的价值，但恢复评价必须先保证失败集合的语义一致。节点缺陷与最终任务失败分别有研究意义，却不能共用一个恢复分母。

5.5 静态与动态依赖图比较

本节直接检验后续策略调整相对固定后继计划的收益。首先报告 100 任务回放，再报告具有真实上游输入传播的 48 任务面板；两者不汇总。[E11—E13]

表 5-9 静态与动态回放比较

回放方法	任务正确率	平均 tokens	服务时长估计（秒）
静态、允许局部回退	0.4100	7,020.5	12.807
动态第一版	0.4000	7,034.6	13.258

回放差异为 -1.00 个百分点，95% 区间 [-3.00,0.00]，差异不显著。它说明有反馈触发和后继选择并不足以保证收益，回放机制跑通也不能替代真实错误传播评价。

48 任务实验的基础模型调用与中间事实真实执行，第二版复用相同静态前缀记录并新增分歧调用。失败检测和失败计数仍读取评价答案，预算依据静态策略最终实际消耗的 1.2 倍设置；该预算是对照实验口径，不是部署前可获得的先验预算。

表 5-10 已分析真实调用面板的策略比较

方法	成功任务	正确率	平均 tokens	平均服务时长（秒）	Help/Harm	重调度任务	token 超预算
静态、允许局部回退	25/48	52.08%	1,402.2	2.95	—	—	基准
动态第一版	26/48	54.17%	1,403.8	2.89	2/1	25/48	0
动态第二版	26/48	54.17%	1,400.6	3.09	1/0	25/48	0

第一版相对静态差异为 2.08 个百分点，原配对区间 [-4.17,10.42]；第二版同样为 2.08 个百分点，本稿逐任务复核区间 [0,6.25]。两者差异均不显著。第二版没有提高成功总数，观察到的损害数从 1 降为 0，同时少了一个帮助案例。平均 tokens 接近静态，服务时长略高，不能写成质量、成本和时延全面改善。

重调度标记覆盖 25 个任务，但其代码定义还包括局部回退，且实验只有两节点链。因此 25/48 不能直接解释为 25 次具有多个后继的全局重规划成功。零 token 超预算也仅限上述实际预算设置；没有证明严格的双预算在线保证。

最新证据支持谨慎的结论：选择性更新在该面板上减少了观察到的负迁移，没有取得统计确立的总体准确率优势。由于样本曾被分析且检测理想化，后续不能把它重命名为未经触碰的独立测试。

5.6 受控故障传播

受控实验从相同事实副本出发，构造 C0 无干预、T1 删除最后一个事实、T2 将最后一个事实值乘 1.5、T3 使用 medium 重新抽取四类条件。T1 需要至少两个事实。冻结候选 33 题，实际形成 C0、T2、T3 各 30 对和 T1 28 对，共 118 对记录。[E14]

为避免错误恢复分母，本表直接从原始配对最终成功字段汇总。原分析脚本将动态成功字段误用于静态恢复计数，并使用不同分母，其恢复率 and 对应区间不作为论文证据。

表 5-11 受控故障的配对最终结果

条件	配对数	静态正确数	动态正确数	Help/Harm	平均 token 差异	服务时长差异 (秒)
C0 无干预	30	16	15	0/1	-2.7	-0.013
T1 证据缺失	28	2	2	1/1	-4.0	+0.039
T2 错误中间值	30	1	1	0/0	-5.3	-0.079
T3 模型分配干预	30	13	15	2/0	-69.7	-0.638

T1 与 T2 未显示净准确率增益，与“仅换推理模型不能可靠补回缺失或错误证据”的解释一致。T3 中动态多完成两题，提供有限的模型互补线索。但该条件同时改变抽取恢复模型与后续推理模型，不能将收益归因于某一个重路由动作。

C0 只有 29/30 对最终结果相同，未满足完全相等的理想对照要求。这提示两臂恢复路径即使在没有人工注入故障时也可能分歧。删除“最后一个事实”也不保证删除的必然是必要操作数。综上，本实验可作为机制性观察，不能作为干净的单因素因果证明；T3 的两例帮助不构成显著优势结论。

5.7 恢复矩阵与预算感知恢复

恢复矩阵使用原最终答案错误的 116 个节点，包含证据类 45、推理类 48、结构类 23。四类动作在冻结运行快照上比较，成功按最终答案判定。[E08、E15]

表 5-12 审计后的单动作恢复计数

真实失败类型	节点数	再次调用成功	切换模型成功	重新取证成功	局部分解成功
证据类	45	0/45	1/45	2/45	1/45
推理类	48	0/48	1/48	1/48	1/48
结构类	23	2/23	0/23	2/23	0/23
合计	116	2/116	2/116	5/116	2/116

各类成功数很少，同一节点还可能被多个动作恢复。表中不支持建立稳定的“失败类型→最优动作”映射；并未通过新的交互效应检验，因此不把这一判断写成严格证明不存在任何关联。再次调用的两个成功也不满足同提示重试语义。

本稿从 116 条原始动作记录补算平均资源开销，避免使用原纠正矩阵中占位的零成本字段。

表 5-13 单动作新增资源开销

单动作	恢复率	平均新增 tokens	平均新增服务时长（秒）
再次调用	1.72%	276.0	0.322
切换模型	1.72%	275.7	0.366
重新取证	4.31%	2,939.1	3.488
局部分解	1.72%	3,030.3	3.900

重新取证覆盖更多失败，但成本也高。单动作平均成本来自所有尝试，不是每个成功任务成本。四动作并集仅恢复 8/116，即 6.90%；这一上界针对当前样本、提示、模型和动作输出固定集合，不是所有未来系统的理论能力上限。

顺序恢复回放进一步比较累计开销。该回放按离线正确性在首次成功时停止，资源消耗由已测动作相加，不等于完整序列重新在线执行。

表 5-14 顺序恢复的覆盖与累计开销

顺序策略	恢复率	95% 任务聚类区间	平均新增 tokens	服务时长（秒）
再次调用→切换	3.45%	[0.82%,7.21%]	544.4	0.681
再次调用→切换→取证	5.17%	[1.67%,9.65%]	3,406.2	4.043
四动作依次执行	6.90%	[2.56%,11.93%]	6,332.3	7.751
当前动作并集 Oracle	6.90%	[2.56%,11.93%]	不解释为可实现成本	不解释为可实现时延

增加动作提高固定集合覆盖，但边际开销迅速增加。预算感知恢复的作用是限制可用动作并决定何时停止，而不是保证每次升级都有收益。

5.8 历史任务图复用

本实验检验修改型追问是否可以复用已有抽取，而只重算依赖变化事实的推理与验证。20 个案例分别将一个事实修改 10%，比较复用方案与重新执行逻辑节点基线。[E16]

表 5-15 历史图的修改型追问复用

指标	结果	口径
修改型追问数	20	特定受控追问负载
复用抽取节点	40	逻辑节点计数
复用后的新调用	40	推理与验证
重新执行基线调用	80	逻辑执行需求
复用率、调用减少率	均为 50%	同一节点需求口径
token 减少率	91.4%	既有基线调用量与新调用记录比较
可执行且响应修改	19/20	执行及数值响应，不是答案正确率
验证器接受	0/20	不支持最终质量已获确认

较大的 token 降幅来自避免重复处理抽取长上下文，而不只是调用次数减半。该结果支持历史图减少重复执行的机制，但基线为逻辑重执行需求，不能等同于所有物理缓存与批处理条件下的账单节省。19/20 只能说明流程可执行且结果随修改变化，不能写成 95% 多轮任务成功率。

版本化修改在小型原型中已保存输入变化与依赖重算。一般语义检索、大规模子图剪枝和长期质量保持没有相应实验证据，本文不作肯定结论。

5.9 多目标与剩余预算分析

预算响应面使用 116 个真实失败节点的四类既有动作记录，在 11 个 token 档位与 7 个时长档位上评估，共 77 个预算组合。[E17] 对每个动作，若其已测开销超出剩余资源则跳过，否则计入消耗；一旦离线评分成功即停止。因此结果是已知动作开销和成功状态的条件化预算分析。

表 5-16 剩余预算与恢复质量

token 预算	服务时长预算 (秒)	四动作顺序策略恢复率	同预算 Oracle	遗憾
500	1	2.59%	3.45%	0.86 个百分点
1,000	2	3.45%	4.31%	0.86 个百分点
2,000	3	4.31%	5.17%	0.86 个百分点
3,000	3	5.17%	5.17%	0
4,500	8	6.03%	6.90%	0.87 个百分点
不设上限	不设上限	6.90%	6.90%	0

紧预算排除大部分取证和分解调用；中等预算开始容纳额外动作；宽松预算最终覆盖固定动作并集。该规律解释了剩余资源为什么必须进入恢复决策。即使不限制预算，仍有 108/116 个节点无法由当前动作集合恢复，说明约束放松不能自动产生新的能力。

离线预算可行性由已知实际开销构造，因此不能把零约束违反宣传为在线预测准确。动态真实调用的预算也由静态实际消耗设定；这两组证据都不足以验证一般部署中的严格双预算保证。

帕累托解释同样局限于可比口径。48 任务面板中，静态消耗 1,402.2 tokens、2.95 秒，动态第二版消耗 1,400.6 tokens、3.09 秒且点估计质量稍高，存在质量、token 与服务时间的权衡；动态第一版的 1,403.8 tokens、2.89 秒又提供另一种点估计权衡。考虑采样不确定性后，不应宣称这些细小差异构成稳定排序。早期回放中“静态、反馈位于前沿”只适用于该候选集合和估算成本，不能跨实验继承为全局结论。

5.10 消融与机制汇总

本节整合各比较，回答收益来自何处，以及哪些新增执行没有扩大覆盖。[E02、E07、E13、E18—E19]

表 5-17 消融与机制结果汇总

机制比较	主要观察	可支持的结论
查询路由→类型先验	新版确认 +6.90 个百分点	类型粒度提供主要路由收益
类型先验→学习式节点路由	新版确认差异为零	未证实表示学习的额外泛化收益

机制比较	主要观察	可支持的结论
初始反馈→状态感知反馈	条件化质量 0.5355 → 0.5822	反馈与额外恢复组合具有回放潜力
动态第一版→第二版	正确数均 26; Help/Harm 由 2/1 → 1/0	观察到较少破坏, 无总体质量增长
全局验证门控→类型门控	新版质量 0.5355 → 0.5477	门控范围在模拟条件下影响代价与误触发
四动作→增加局部重规划	开发 40 节点覆盖均 4/40	没有新增可恢复节点, 按预设规则不继续

类型门控消融使用测得验证器混淆信息进行零新增生成回放, 不是对每个当前输出新执行独立验证。其恢复计数不直接等于质量净增量, 不能使用旧版不一致 Oracle 字段解释新质量。

局部子图重规划在 40 个开发节点上仅成功 1 个, 与现有动作重叠; 加入前后并集均为 10%。平均约 5,930.6 tokens、5.505 秒, 高于局部分解的约 2,668.4 tokens、3.737 秒, 未达到预设新增覆盖要求。[E19] 这一负结果支持将动态执行定义为反馈条件化调度, 而非强制拓扑改写, 但不证明所有拓扑调整均无效。

历史正式回放中的 22%/27%/56% 与 50 任务旧综合调用中的 24%/28%/34% 属于不同协议, 不能串联成动态第二版的改进轨迹。前者依赖回放与理想检测, 后者存在标准事实回退等历史限制; 后续失败重审计并不会自动消除其全部信息边界。本稿保留这些记录在证据映射中, 不再将其作为最新主表。[E20]

待我确认项: 受控故障的原恢复率统计有实现错误, 本稿只保留原始配对计数; 复杂度表只能作探索性证据; 图复用未证明答案质量; 所有新版复核均未触发新模型调用。决定投稿表格范围时, 建议保留这些限定。

6 讨论

6.1 动态改善为何有限

初始节点分配和动态恢复解决不同问题。节点路由能够利用稳定的类型差异, 而动态恢复发生在初始方法已经失败的困难子集上。后者不仅要求替代模型更合适, 还要求输入中保留足够证据、失败被正确识别、剩余资源允许执行。任何一个条件不成立, 更新计划都可能只增加开销。

48 任务实验中第二版消除了观察到的一例损害, 却没有增加总体正确数, 说明抑制错误更新与扩大恢复覆盖不是同一能力。受控故障中, 模型分配干预出现少量帮助, 证据缺失和错误值没有净改善, 与这一解释一致。但理想检测、小样本和对照分歧限制了其普遍性。

6.2 模型互补性与候选能力边界

节点 Oracle 与真实失败动作 Oracle 度量不同机会。前者衡量在给定节点输入上选择哪个模型更好; 后者衡量困难失败样本能否被既有恢复输出解决。节点面板的正差距不能直接转换成失败恢复潜力。

在固定模型、提示、输入快照和动作输出集合 A 下, 可恢复集合为各动作成功集合的并集。调度器可以减少选错动作或无效调用, 却不能选择一个集合中不存在的正确输出。这是本文“能力覆盖上限”的严格含义。它不是关于任何未来模型池、工具或新提示的绝对上限, 也不意味着所有在线探索都没有价值。

6.3 失败判据与监督信息纯度

32 个原本答案正确的候选说明，按中间缺陷定义失败与按最终正确性定义失败会产生不同研究对象。如果问题是提高证据完整性，应报告证据召回变化；如果问题是恢复最终任务，应排除原本正确的任务，并同时计入新造成的损害。

标准事实和离线答案也需要在不同位置分别审计。即使恢复提示没有答案泄漏，调度器仍可能通过标准答案触发恢复；即使实际事实正确传播，理想停止条件仍可能低估成本。可靠结论需要同时检查输入、触发、选择、停止和评分五个信息接口。本文的后期结果已改善失败集合口径，但不能据此声称所有实验均已获得完全在线信息条件。

6.4 局限性

研究主要覆盖财务数值问答和有限模板图，尚不能推广到开放式生成和大型分支 DAG。类型先验在独立面板上已解释主要路由增益，更丰富的问题表示没有获得稳定跨域优势。推理动作依赖固定表达式接口，接口错误与模型能力有时仍然交织。

动态面板规模有限且被重复分析，第二版确认不是未经触碰的独立测试。部分真实调用试验使用标准答案判定失败，预算回放使用实际开销和离线停止条件，因此部署可行性证据弱于机制证据。受控故障无干预条件仍有一例分歧，进一步限制单因素解释。

历史图实验仅有 20 个受控追问，验证器全部未接受，故资源收益不能替代质量证据。成本以 tokens 计，时延多为服务时间而非端到端时间，不同模型量化和加载方式也影响外推。不同实验的缓存、去重和条件输入口径应保留，不能通过合并平均值消除这些差异。

待我确认项： 本稿将理想失败检测、已分析面板和资源代理作为核心局限，而非脚注；这些限制会影响论文可主张的实证强度，应在最终摘要与结论中继续保留。

7 结论

本文研究复杂任务中基于能力画像的多模型协同执行，构建从任务分解和节点路由，到反馈条件化调整、预算感知恢复与历史图复用的统一框架。实验证据表明，节点类型粒度能够利用模型异质性；在冻结确认面板上，节点路由优于查询路由，但未超过类型先验。分解与恢复并非普遍有益，其收益取决于输入证据、任务结构和候选能力覆盖。

最新动态策略在已分析真实调用面板上保持与第一版相同的成功总数，并减少观察到的负迁移；其相对静态差异不显著，且仍受理想失败检测限制。经最终答案审计后，固定恢复动作只覆盖少量真实失败，预算放宽无法突破这一已记录输出集合。历史图显示了降低重复执行的可行性，但最终质量与大规模复用仍需进一步证据。

因此，本文支持的结论是：反馈感知调度可以在明确的信息与资源边界内利用既有模型互补机会，但不能保证创造当前候选集合之外的正确解。节点级分配、真实失败审计和受约束动态更新应共同构成复杂任务路由的评价基础。

待我确认项： 结论不再保留动态显著胜出、拓扑重规划提高覆盖或图复用已达到高答案正确率等旧说法。

参考文献

- [1] Ong, I., et al. RouteLLM: Learning to Route LLMs with Preference Data. 2024. arXiv:2406.18665. 原文.X
- [2] Chen, L., Zaharia, M., and Zou, J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance. 2023. arXiv:2305.05176. 原文.
- [3] Kim, S., et al. An LLM Compiler for Parallel Function Calling. 2024 年修订版, arXiv:2312.04511v3. 原文.
- [4] Madaan, A., et al. Self-Refine: Iterative Refinement with Self-Feedback. 2023. arXiv:2303.17651. 原文.
- [5] Wang, Z. Z., Mao, J., Fried, D., and Neubig, G. Agent Workflow Memory. 2024. arXiv:2409.07429. 原文.
- [6] MultiHiertt: Numerical Reasoning over Multi Hierarchical Tabular and Textual Data. ACL 2022. 正式论文页面.
- [7] TAT-QA: A Question Answering Benchmark on a Hybrid of Tabular and Textual Content in Finance. ACL-IJCNLP 2021. 正式论文页面.