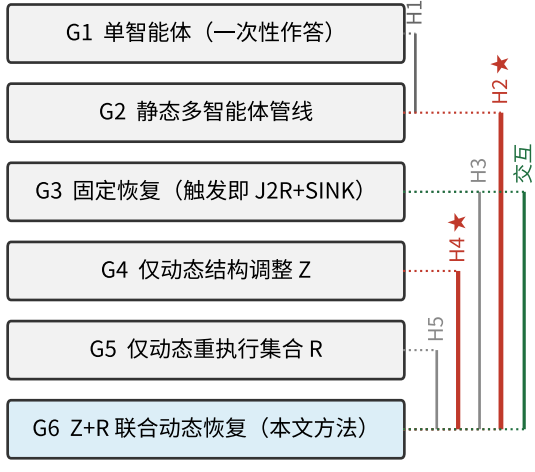
(a) 六个实验臂与配对比较



★ = Holm 族（α=0.05）下成立：H2（G6−G2）、H4（G6−G4）；交互 q=G6−G4−G5+G3（双侧）

每臂同一任务同一 Gold 与评分器；共享上游检查点分摊到各臂

(b) 区组结构（52 个，预登记随机化）

26 个真实任务 × 2 次重复 = 52 区组
（种子=int(冻结清单SHA[:8])=2756364533）

区组内：共享上游 E×2 → J1 → J2（检查点，先于全部分叉臂）

G2	G3	G6	G1	G5	G4

G2 固定先行（检查点依赖）；G3–G6 随机排列；G1 独立随机插入

统计单位 = 26 个独立任务（k=2 重复取均值后做配对检验）

硬预算（预执行门禁）：≤1300 次调用；≤15M tokens；≤¥24（元，统一价格表）
实际：507 次 / 4.23M / ¥6.94